

分类号: _____

密级: _____

UDC : _____

编号: _____

工学硕士学位论文

通信侦察中的盲源分离技术研究

硕士研究生：许鸿瑞

指导教师：张晓林 副教授

学科、专业：通信与信息系统

论文主审人：安澄全 副教授

哈尔滨工程大学

2014 年 1 月

分类号：_____

密级：_____

UDC：_____

编号：_____

工学硕士学位论文

通信侦察中的盲源分离技术研究

硕士研究生：许鸿瑞

指导教师：张晓林 副教授

学位级别：工学硕士

学科、专业：通信与信息系统

所在单位：信息与通信工程学院

论文提交日期：2014年1月13日

论文答辩日期：2014年3月13日

学位授予单位：哈尔滨工程大学

Classified Index:

U.D.C:

A Dissertation for the Degree of M. Eng

Research on Blind Source Separation Technology in Communication Reconnaissance

Candidate: Xu Hongrui

Supervisor: Associate Prof. Zhang Xiaolin

Academic Degree Applied for: Master of Engineering

Specialty: Communication and Information System

Date of Submission: Jan. 2014

Date of Oral Examination: Mar. 2014

University: Harbin Engineering University

哈尔滨工程大学

学位论文原创性声明

本人郑重声明：本论文的所有工作，是在导师的指导下，由作者本人独立完成的。有关观点、方法、数据和文献的引用已在文中指出，并与参考文献相对应。除文中已注明引用的内容外，本论文不包含任何其他个人或集体已经公开发表的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者(签字)：

日期： 年 月 日

哈尔滨工程大学

学位论文授权使用声明

本人完全了解学校保护知识产权的有关规定，即研究生在校攻读学位期间论文工作的知识产权属于哈尔滨工程大学。哈尔滨工程大学有权保留并向国家有关部门或机构送交论文的复印件。本人允许哈尔滨工程大学将论文的部分或全部内容编入有关数据库进行检索，可采用影印、缩印或扫描等复制手段保存和汇编本学位论文，可以公布论文的全部内容。同时本人保证毕业后结合学位论文研究课题再撰写的论文一律注明作者第一署名为哈尔滨工程大学。涉密学位论文待解密后适用本声明。

本论文(☐在授予学位后即可 ☐在授予学位12个月后 ☐解密后)由哈尔滨工程大学送交有关部门进行保存、汇编等。

作者(签字)：

导师(签字)：

日期： 年 月 日

年 月 日

摘 要

随着通信技术的发展和电磁环境的日益复杂, 实际环境中的电磁信号变得日益密集。经常出现多个信号在时域和频域均发生混叠的现象, 作为通信侦察的需要, 首先要将所需的敌方通信信号从混合信号中提取出来。就目前已有的分离方法来看, 时频域分离方法和空域分离方法都不能够很好的将同频混叠信号分离。这给通信侦察系统对非合作信号的分析与识别带来了巨大的困难。因此, 目前迫切需要研究可行的处理方法, 实现通信侦察信号的有效分离。盲源分离技术正好能够解决这一难题。它能够在不知道信号的任何先验信息的情况下, 仅利用源信号之间相互独立这一微弱已知条件, 从一组接收天线接收到的混合信号中分离出独立的源信号。本文主要研究盲源分离技术在通信侦察系统中的应用。

本文在深入研究盲源分离的相关理论的基础之上, 以峭度的时间平均形式 (TAFC) 作为独立性的度量, 从理论上证明了盲源分离算法可以分离确定的余弦信号, 甚至是同频余弦信号。启发人们应用盲源分离技术分离复杂的余弦信号 (通信信号、雷达信号)。将盲源分离技术应用于现有的通信侦察系统, 提出基于 NI PXI 的通信侦察接收系统的软件和硬件设计方案。通过实验仿真讨论了信号载频间隔、信噪比和取样时间长度对分离性能的影响。

提出改进的基于负熵的 FastICA 算法。改进算法在将最速下降法与牛顿迭代算法相结合的基础上, 进一步在牛顿迭代过程中采用部分牛顿迭代, 使得改进算法具有更高并且均匀一致的迭代速度。通过仿真试验证明其对数字调制通信混合信号的分离的有效性。

针对跳频信号的非平稳特性, 提出一种基于时频矩阵的同时非正交联合对角化和非对角化盲源分离算法 (JDZD)。该算法同时利用来自于自项区和交叉项区的时频分布矩阵, 建立统一的代价函数, 通过增加时频点来减少特征值退化的可能性, 从而增强了抗噪能力。理论分析和仿真结果表明, 该方法能够在低信噪比的条件下, 有效分离多个跳频网台。

关键词: 盲源分离; 通信侦察; 快速固定点算法; 联合对角化; 同频信号

ABSTRACT

With the development of communication technology and the increasing of complex electromagnetic environment, the physical environment of the electromagnetic signal becomes more dense. Multiple signals are often aliasing in both time domain and frequency domain. In order to meet the needs of communication reconnaissance, we need to separate the enemy communication signals from the mixed signals firstly. At present, both the time-frequency domain separation method or airspace separation methods all can not separate the same frequency aliasing signal. This brought great difficulties to communications reconnaissance systems in analysis and identification of non-cooperative signals. Therefore, there is an urgent need to study the feasibility processing methods to achieve separating of communication signals effectively. Blind Source Separation techniques just to solve this problem. It can separate independent source signals from the mixed signals which received by the antenna using a weak condition that the source signal are independent, without knowing any prior information of signal. This paper mainly studies the blind signal separation technology applied in communication reconnaissance system.

Based on in-depth study of the theory of blind source separation, this paper introduced time average fourth cumulant(TAFC) as a measure of independence, theoretically proved blind source separation algorithm can successfully separate determinate cosine signals, or even same frequency cosine signals. Which inspires people to apply blind source separation techniques on complex cosine signals (communication signals, radar signals). We applied the blind source separation technique to existing communications reconnaissance systems, and proposed software and hardware design solutions based on NI PXI communication reconnaissance of the receiving system. For communications reconnaissance signals, simulation tests proved the aliasing extent of each source spectrum does not affect the separation efficiency of the algorithm. If the sampling frequency meets certain requirements, SNR and sampling time are the main factors which affecting the separation result.

This paper proposes an improved algorithm based on negative entropy FastICA. The improved algorithm combined the steepest descent method and Newton iteration algorithm, and further using Part of the Newton iteration in Newton iterative process, so that the improved algorithm has higher and uniform iteration speed. Through simulation experiment,

we prove it has a good effectiveness on separation of digital modulation mixed signal.

According to frequency hopping signals have typical non-stationary characteristics, This paper presents an algorithms of Nonorthogonal Joint Diagonalization and Zero Diagonalization for source separation based on time-frequency distributions(JDZD). This algorithms not only uses the diagonalization part of auto-source term of time-frequency matrix, but also use the zero diagonalization part of cross-source term of time-frequency matrix. It established a unified cost function, to reduce the possibility of eigenvalues degradation by increasing the time-frequency points. Theoretical analysis and simulation results show that this method can effectively separate multiple frequency-hopping network stations in low SNR conditions.

Key words: Blind source separation (BSS); Communication reconnaissance; FastICA; JADE;
Same frequency signal

目 录

第1章 绪论	1
1.1 课题研究的背景及意义	1
1.2 通信侦察技术的概念	1
1.2.1 通信对抗的含义	1
1.2.2 通信侦察的含义	2
1.3 盲源分离技术简介	2
1.4 通信混合信号盲分离的研究现状	3
1.5 论文的主要研究内容及章节安排	5
第2章 混合信号多通道盲源分离的理论基础	7
2.1 瞬时线性混合系统模型	7
2.2 信号预处理	9
2.2.1 混合信号中心化	9
2.2.2 混合信号白化	9
2.3 基于盖尔圆理论的信源个数估计方法	10
2.4 独立性准则	14
2.4.1 非高斯最大化准则	14
2.4.2 信息最大化准则	15
2.4.3 联合对角化准则	16
2.5 主要分离方法	17
2.5.1 联合对角化算法 (JADE)	17
2.5.2 信息最大化算法 (Infomax)	20
2.5.3 等变自适应分解算法 (EASI)	21
2.6 盲源分离性能评价指标	22
2.7 本章小结	23
第3章 同频侦察信号的盲源分离技术研究	24
3.1 概述	24
3.2 确定正弦信号的盲源分离	24
3.2.1 峭度和独立性	24
3.2.2 时间平均峭度 (TAFC)	26

3.3 基于 NI PXI 通信侦察接收平台设计和开发	28
3.3.1 基于 NI PXI 的盲分离硬件接收平台	28
3.3.2 基于 NI PXI 的盲分离软件接收平台	28
3.4 盲源分离试验仿真	29
3.4.1 盲源分离原理性试验仿真	30
3.4.2 信号源载频间隔对分离性能的影响	32
3.4.3 信噪比对分离性能的影响	35
3.4.4 取样时间长度对分离性能的影响	36
3.5 本章小结	38
第 4 章 基于负熵的 FastICA 改进算法研究	39
4.1 概述	39
4.2 改进的基于负熵的 FastICA 算法	39
4.2.1 基于负熵的 FastICA 算法	39
4.2.2 降低 FastICA 的初值敏感度	42
4.2.3 提高 FastICA 的迭代速度	43
4.3 改进算法的计算机仿真及性能分析	43
4.4 本章小结	46
第 5 章 基于时频矩阵的跳频网台盲源分离方法研究	48
5.1 概述	48
5.2 跳频通信侦察数字化信道接收系统	48
5.3 基于平滑伪魏格纳维尔分布(SPWVD)的时频分布矩阵	49
5.4 基于时频矩阵的非正交联合对角化和非对角化盲源分离	50
5.4.1 时频点的选择	50
5.4.2 代价函数	52
5.4.3 优化算法	54
5.4.4 分离步骤	55
5.5 试验仿真	56
5.6 本章小结	59
结 论	60
参考文献	62
攻读硕士学位期间发表的论文和取得的科研成果	66

致 谢 67

第1章 绪论

1.1 课题研究的背景及意义

在现代战争中，通信侦察以其特有的作战方式和作战能效扮演越来越重要的角色，是信息致胜的关键，同时也是打赢未来战争的关键。目前，现代通信技术不断发展，先进干扰技术也不断涌现，这使得电磁环境变得日益复杂。通信侦察面临着越来越大的生存威胁。现有的通信侦察手段已经不能满足现代战争的需要，通信侦察的相关技术需要进一步发展更新。

在实际的通信侦察中，通信侦察接收机截获到的信号往往包含多方信号，可能包含敌我双方的通信信号、各种干扰信号和噪声。因此要想从截获的信号中获得有效的敌方信息，首先必须从截获到的混合信号中分离出所需的敌方通信信号。目前常用的时频域分离方法和空域分离方法都具有很大的局限性，时频域分离要求待分离源信号必须在时频域上具有聚类性，即各源信号在任意时刻的瞬时频率是可分的，对各个时刻源信号频谱均重叠的情况则无法分离。空域分离方法采用阵列天线对多个空间信号进行接收，通过调制各阵元的加权系数，使阵列天线方向图的主瓣指向所需方向。波束形成技术是主要的空域分离方法^[1]。但是，空域分离方法在波束形成之前必须对目标信号的来波方向（Direction of Arrival, DOA）进行估计。而在实际应用中，天线阵列的方向矩阵往往无法得到或者不够准确（如 DOA 估计不够精确），在这种情况下，依赖阵列方向矩阵的波束形成技术就无法实现混合信号的分离和提取。而盲分离方法只利用天线阵列接收到的混合信号就可以实现信号分离，不需要知道阵列方向矩阵，因而对阵列模型误差不敏感。针对盲源分离方法具有的理论优势，本文重点开展盲分离算法的研究及盲分离技术在通信侦察系统中的应用。

1.2 通信侦察技术的概念

1.2.1 通信对抗的含义

通信对抗亦称通信电子战，是电子对抗的重要分支，指在电子战中削弱、破坏敌方无线电通信系统的使用效能和保护己方无线电通信系统使用效能的正常发挥所采取的措施和行动。

近年来，随着信息技术、通信技术和计算机技术的迅速发展以及军事转型的推进，通信对抗的内涵也扩大了许多、它不但使用通信干扰的“软”武器压制来扰乱敌方的信息传递，而且还大量使用通信欺骗和心理战协作战争，以获得迟滞对方的反应、判断、

决策和行动等效果,甚至使用精确制导武器、定向能武器、反辐射武器和隐形武器等“硬”武器来摧毁敌方通信指挥重要节点。

1.2.2 通信侦察的含义

通信侦察、通信电子进攻和通信电子防御是通信对抗包含的主要三个方面。通信侦察更是通信对抗的重要分支,通过采取多种措施来搜索和截获敌方信号,对其进行识别和分析以获得敌方通信信号的技术参数,并实施定向侧位、控守监视和引导干扰等。通信侦察不仅能够为通信对抗提供强有力的情报保障,也能够为通信电子进攻和防御提供依据。

通信侦察设备往往具有其他通信设备所不具有的特征,能够在密集的信号环境和超宽的频带范围内对各种类型的信号实现较高概率的截获,并进行情报收集分析、侧向定位和报告。目前,通信侦察系统已能对高频和甚高频的常规(既非扩频)通信和跳频通信信号进行截获和分析处理,能对超高频和特高频的常规通信信号进行侦收。美军通信侦察设备的频谱范围已覆盖 100kHz 到 18GHz(可扩展到 40GHz),灵敏度达-110dBm,动态范围达 95dB,截获概率几乎达到 100%。在高密集的电磁信号环境中,可准确地进行分析识别和跳频网台的分选。

1.3 盲源分离技术简介

针对盲分离的研究最初起源于鸡尾酒问题,在嘈杂的环境中,每个麦克风接收到的是多个说话者的混合声音,如何仅仅从话筒接收到的语音信号中分离出所需要的单个说话者的声音,这便是盲源分离问题^[2]。盲源分离(BSS, Blind Source Separation)是指在信号的先验信息和混叠形式均不能获得的情况下,仅根据接收信号分离出各信号源的过程^[3]。

BSS 技术在信号处理领域有着广泛的应用,如话音信号、生物医学信号、图像信号、地震信号、机械信号、声呐信号等^[4]。随着通信的发展,盲源分离技术逐步在通信领域里得到应用。并与其它信号处理技术,如时频分析、高阶谱分析、小波分析、神经网络信号处理等现代通信信号处理技术相结合。尤其是在无线通信和生物医学等方面的成功应用,促使其得到迅速发展。目前已经成为信号处理中一个极富挑战的研究领域,发展极为迅速,新理论、新方法还在源源不断地涌现。

至今,盲源信号分离算法已形成基于信息论、统计学、神经网络、系统论和信息几何等七大类的主要算法^[5],分别为:信息最大化、互信息最小化、负熵最大化、最大似

然估计、高阶矩和累积量、非线性主成分分析以及自适应均衡算法(Bussgang)。

Comon 首先提出了盲源信号分离的独立分量分析方法(ICA)^[6]。ICA 与 BSS 的区别在于,ICA 是根据信号源之间的独立性,对混合信号进行分离。而 BSS 不论信号源是否独立,都尽力将混合信号分离。本文在讨论盲源分离问题时,首先假设信号源是相互独立的。BSS 的假设条件是与 ICA 一致的,因此本文对 ICA 和 BSS 两个概念不加以区分。

1.4 通信混合信号盲分离的研究现状

随着现代通信技术的不断发展,信号处理技术的不断取得进步。Marconi 发明无线电的时候可能不会想到,当他同时接收两个以上信号将如何处理。而至今,天空中充斥着各种各样的电子信号,信号混叠情况时有发生。这里的混叠指的是信号时域和频域均发生重叠,并且不存在极化等正交可以区分的办法。此时,传统针对单信号的处理方法已不在适应,混合信号处理技术便应运而生^[7]。

混合信号处理最开始面临的一个问题是,如何从接收混合信号中提取出感兴趣的信号,而抑制掉不感兴趣的信号。不感兴趣的信号一般称之为干扰,相应的技术称为干扰抑制技术。这个问题的产生主要是因为频率复用技术的发展。1974 年,贝尔实验室首先提出了蜂窝移动通信的概念,通过划分蜂窝小区,相邻蜂窝使用不同频率通信来提高频谱效率。移动通信市场的发展,使得蜂窝通信已从 20 世纪 80 年代初基于 FM 调制和频分多址 FDMA 的第一代模拟蜂窝,20 世纪 90 年代基于码分多址 CDMA 的第二代数字蜂窝,发展到今天基于微蜂窝结构的第三代通信。蜂窝通信在提供更多业务和容量的同事,频率复用率越来越高,带来的用户间的相互干扰也越来越严重。干扰抑制技术能大大改善系统的性能,如 Winter 提出采用分集合并的方法克服干扰^[8],Yoshino 提出干扰抵消均衡器并应用在瑞利衰落信道下^[9],串行干扰抵消技术^[10]与并行干扰抵消技术^[11]提出并受到关注,多用户检测器在克服多址干扰上具有优异的性能。正是这些处理技术的发展,带来了移动通信技术的进步与繁荣。

当接收到的混合信号中感兴趣的信号不止一个时,干扰抑制技术已无法满足要求,此时需要将多个信号进行分离,这促进了分离技术的发展。1986 年,Jutten 和 Herault 基于源信号的统计独立性,提出了一种基于反馈神经网络,通过选取齐次非线性函数构成 Hebb 训练的方法,实现了两个混叠源信号的分离^[12]。Jutten 和 Herault 的这一工作标志着盲分离这一新兴研究方向的开始。20 世纪 90 年代,这一方向吸引了很多学者的关注,相关的研究蓬勃发展。这里的盲分离,指的是根据源信号来波的方向差异,采用阵列天线进行接收,通过估计出源信号混合矩阵来实现分离的技术。在盲分离理论上取得

进展后，人们开始将其用于实际应用。Lee 和 Bell 将基于最大似然的盲分离算法用于真实语音信号分离^[13]，实验表明能使得分离后语音的识别率得到提高。一些基于神经网络的盲分离算法应用到图像特征提取与医学脑电信号分离上^[14]，取得了较好的效果。

前面的盲分离有一个基础，即采用阵列天线（或传感器）进行接收，且假定阵元个数不少于源信号个数。在通信领域，随着电磁信号形式的日趋多样化，接收到混叠信号的概率也大大增加。这些混叠信号一方面是由于无线电频段上的信号日益密集所致，如美国 GPS 系统和欧洲 Galileo 系统在 1176MHz 和 1575MHz 两个频点上均存在信号^[15]，蜂窝通信中采用的频率复用技术使得当前小区用户会受到邻近同频小区信号的干扰；另一方面，通信对抗和反对抗中人为释放的干扰，也可能造成接收信号被干扰信号污染而成为混叠信号；另外，新型通信体制的采用，如卫星成对载波多址技术^[16]，卫星蜂窝通信如 Inmarsat、ACeS 和 Thuraya 系统等，以及新规则的制定。如已有国家向国际电信联盟（International Telecommunication Union, ITU）提出减少同步轨道卫星之间角度间隔的申请，将其由 1.5° 调整带 1.0° 甚至更低，也可能造成混叠信号的产生。除了传统的信号接收需要对干扰进行分离以提高系统性能外，在诸多领域常常需要对未知信号进行非合作接收处理，尤其是军事领域中的需求愈加突出，如频谱监测、威胁评估、电子对抗等，而混合信号的出现给这些应用造成了极大的困难。某些情况下这些信号可采用阵列天线分离的方法进行处理，而某些情况下阵列天线分离的方法并不适合。

以邻星干扰为例。当同步轨道上的卫星靠得过近时，相互之间就有可能形成干扰，如图 1.1 所示。由于传输距离比较远，对于地面接收站而言，相邻卫星来波方向差异很小，用阵列天线接收时混合矩阵可能病态。这时需要仅根据一路接收信号分离出多路源信号，相应的方法称为单通道盲分离。此外，阵列天线接收受天线架设位置和架设成本的约束，有时难以达成，而单天线接收条件总是能满足的。如在频谱资源管理与监测中，通常采用一个大面积接收天线来覆盖尽可能大的接收区域，此时接收区域内的各种无线电信号有可能在接收端形成同频干扰。




图 1.1 邻星干扰示意图

同频复用技术在现代通信中越来越广泛的应用,使得采用盲分离技术对信号进行分离的需求越来越大。按接收端天线的个数将盲源分离进行分类,可分为多通道盲源分离和单通道盲源分离。一方面,已有的多通道盲分离研究主要集中在语言、生物医学等自然信号的处理上,这些信号与通信信号存在区别,相应的研究成果不一定适合于通信信号处理;另一方面,单信道盲分离是盲分离研究中的难点,不确定因素的大量存在导致求解难度高于多通道盲分离,目前的研究水平甚至不能将信号进行分离。需要结合通信信号特征来研究适合于通信信号处理的盲分离算法,如根据具体的通信信号特征增加约束条件后研究单信道盲分离的可解条件及分离算法。

混合信号盲分离由于“盲”处理的特点,计算复杂度通常较高,而信号处理理论的发展以及大规模集成电路的出现,为盲分离技术的发展和实现奠定了基础。多通道盲分离技术是当前研究的主流,而单信道盲分离技术正逐步受到重视,两者各有优点,分别适合于不同的应用场合,同时又相互补充,共同构成完整的盲分离理论架构。本文将主要研究通信混合信号的多通道盲分离技术。

1.5 论文的主要研究内容及章节安排

通信侦察为了监测尽可能大区域范围内的信号,一般采用全向高增益天线,从而使得侦察区域内的大量信号进入接收端,从而使相同频段的信号或者频段有交叠的信号就会在接收端形成同频混叠信号。因此盲源分离技术在通信侦察中发挥着越来越重要的作用。本文将盲源分离技术应用到通信侦察系统中,提出改进算法以适应通信侦察系统,并通过仿真验证其有效性。

全文一共分为五章,每章内容介绍如下:

第1章为绪论,首先阐述了课题的研究背景和意义,然后介绍了通信侦察技术、盲源分离技术的相关概念,最后介绍了通信混合信号盲源分离技术的发展现状,在此基础上给出了本文的主要工作安排。

第2章主要介绍混合信号多通道盲分离的理论基础,对瞬时线性混合模型做了简单的介绍,并对混合信号的预处理和信源个数估计进行了简要分析。重点对盲分离所依据的独立性准则和主要分离方法做了介绍,为后续盲源分离技术在通信侦察系统中的应用建立起理论基础。最后给出两个分离性能评价指标。

第3章以峭度作为独立性的度量,从理论上证明了盲源分离算法同样可以分离确定的余弦信号,为将盲源分离算法应用于分离复杂的余弦信号(雷达信号、通信信号)提供理论依据。将盲源分离算法应用于通信侦察系统,提出基于 NI PXI 的通信侦察系统

设计理念。通过试验仿真进一步探讨盲源分离算法性能与各信源中心频率、信噪比以及取样时间长度的关系。

第4章对传统基于负熵的快速固定点算法进行改进。改进算法在杨俊安提出的将最速下降法与牛顿迭代算法相结合的基础上,进一步在牛顿迭代过程中采用部分牛顿迭代。在保证改进算法具有均匀一致的迭代速度的同时,进一步获得较高的迭代和收敛速度。改进算法更加适合通信侦察系统中的数字通信混合信号的分离。

第5章提出一种基于时频矩阵的非正交同时对角化和非对角化盲源分离方法。该方法同时在时频分布的自项区和交叉项区上选择时频点,不仅利用自项区时频矩阵的对角化结构,也利用交叉项区时频矩阵的非对角化结构。通过增加矩阵的数改善算法的性能。理论分析和试验仿真结果表明,该方法能够在低信噪比的条件下,有效分离多个跳频网台。

最后是结论部分,对全文的内容进行了总结和展望。

zhi ku quan 20150807

第2章 混合信号多通道盲源分离的理论基础

混合信号多通道分离通常是利用源信号的时频域信息、源信号间空域信息以及源信号间的统计独立性来实现分离。根据利用源信号信息的不同,可把多通道分离方法分为时频域分离方法、空域分离方法以及盲源分离方法。

目前较多使用的是时频域信号分离技术,如各种类型的滤波器。然而,时频域分离方法的局限性在于:待分离源信号必须在时域频域上具有聚类特性,即各源信号在任意时刻处的瞬时频率是可区分的,对各个时刻源信号频谱均重叠的情况则无法分离。

空域分离方法是指当空间存在多个信号源时,利用各源信号空间位置的不同和信号来波方向上的差异对这些信号进行分离,以便跟踪或检测感兴趣的目标信号。空域分离方法是阵列信号处理的一个重要研究领域,采用阵列天线对多个空间信号进行接收,通过调制各阵元的加权系数,使阵列天线方向图的主瓣指向所需方向。空域分离方法常常采用波束形成技术^[17]。然而,空域分离方法在波束形成之前必须对目标信号的来波方向(Direction of Arrival, DOA)进行估计。在实际应用中,天线阵列的方向矩阵往往无法得到或者不够准确(如DOA估计精度不够),这将进一步导致信号无法分离。而盲分离方法只利用天线阵列接收到的混合信号就可以实现信号的分离,不需要知道阵列方向矩阵,因而对阵列模型误差不敏感。盲源分离方法具有的优势备受学者关注,发展极为迅速,已经成为了信号处理中一个极富挑战性的研究领域。

就现有的混合模型主要有两种:(1)瞬时混合信号的盲分离;(2)动态或卷积混合信号的盲分离。目前,针对动态或卷积的混合模型的研究还不够完善并且较为复杂,所以本文只在瞬时混合模型的基础上对盲源分离问题进行研究。多通道盲源分离可分为超定盲分离、正定盲分离和欠定盲分离。前两者中接收信号个数大于或等于源信号个数,因此从纯数学角度考虑是可解的;欠定盲分离中接收信号个数小于源信号个数,从数学角度考虑是无解的,必须借助源信号的某些特性如稀疏性、有限符号集特性等增加约束方程后进行求解。本文仅考虑正定和超定的情况。

2.1 瞬时线性混合系统模型

设信号源为 $s(t) = \{s_1(t), s_2(t), \dots, s_n(t)\} (m \geq n)$ 、混合矩阵为 A 、接收到的观测混合信号为 $x(t) = \{x_1(t), x_2(t), \dots, x_m(t)\}^T = As(t)$ 、输出信号为 $y(t) = \{y_1(t), y_2(t), \dots, y_m(t)\} = Cx(t)$ 。盲源分离技术就是仅根据观测信号 $x(t)$, 利用信号源之间的独立性,使得输出信号 $y(t)$ 逼近于信号源 $s(t)$ 。其中, m 代表源信号的个数, n 代表接收天线阵元个数。盲源分离

的线性混合模型可以用表达式表示为：

$$x(t) = A s(t) + n(t) \quad (2-1)$$

其中， $A(m \times n)$ 为混合未知矩阵 a_{ij} ， $n(t)$ 为噪声。其矩阵表达式为：

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ \vdots \\ s_n \end{bmatrix} + \begin{bmatrix} n_1 \\ n_2 \\ \vdots \\ n_n \end{bmatrix} \quad (2-2)$$

a_{ij} 是混合系数，各个独立信号源 s_i 经过混合系数的线性混叠，再加上传感器噪声 n_i ，就可以得到天线所接收到的观测信号 x_i 。根据得到的观测信号，利用盲源分离技术，构造一个分离矩阵 $C = WU$ ，并对其进行估计，进而求出源信号的估计值。分离矩阵 C 的求解过程可分为两步实现，如图 2.1 所示。




图 2.1 盲源分离系统模型图

首先求白化矩阵 W ，使输出 $z(t)$ 的各分量方差为 1 且互不相关，但不一定独立；然后求正交矩阵 U ，使输出 $y(t)$ 的方差保持为 1，同时各分量尽可能相互独立，如果不考虑噪声，分离信号可以表示如下。

$$y(t) = Uz(t) = UWx(t) \quad (2-3)$$

盲分离主要是利用源信号之间的独立性将各源信号分离开。分离后的信号存在幅度不确定性和顺序不确定性。这些不确定性并不影响信号的后续分析，因为信息只是承载在信号的波形上。

对独立信号进行盲源分离还需另外一些假设条件，如下：

- (1) $m \times n$ 阶混合矩阵 $A(m \geq n)$ 列满秩，但矩阵本身未知；
- (2) 源信号 $s(t)$ 的各分量 $s_i(t)$ 为零均值的平稳随机过程；
- (3) $s(t)$ 最多只能有一个高斯信号。
- (4) $s(t)$ 的各分量 $s_i(t)$ 具有单位方差；

对于正(超)定盲源分离，约束条件 (1) 和 (3) 是必须满足的。约束条件 (2) 和 (4) 可以使分离过程简化，即使不满足，也可以通过预处理使均值近似为零，方差等效为 1。

2.2 信号预处理

为了简化盲源分离算法的计算量，进一步提高分离性能，在实施分离之前通常对接收到的混合信号做预处理。预处理主要包括两个方面：中心化、白化，这里逐一做出简要介绍。

2.2.1 混合信号中心化

信号中心化，就是利用减去均值的方法将混合信号向量 x 变成均值为零信号。可以用式 (2-4) 表示：

$$\bar{x} = x - E\{x\} \quad (2-4)$$

在信号数字化处理过程中很难取得信号的期望，常以算数平均还替代。设 $x(t)$, $t=1,2,\dots,N$ 为随机矢量 x 的 N 个样本，去除样本均值的表达式为：

$$\bar{x}_i(t) = x_i(t) - \frac{1}{N} \sum_{i=1}^N x_i(t) \quad i=1,2,\dots,n \quad (2-5)$$

2.2.2 混合信号白化

如果一个零均值向量 $z = \{z_1, \dots, z_n\}^T$ 的各个分量 z_i 是不相关的且具有单位方差，就称随机向量 z 是白的（球面的）。白的一个近义词是球面的，根据已知的接收信号 x ，通过寻找线性变换矩阵 W （称之为白化矩阵），得到变换后的向量组 z ：

$$z = Wx \quad (2-6)$$

式中， z 就是白化后的信号。白化后的各个信号是不相关的，即满足 $E\{z_i z_j\} = \delta_{ij}$ ，其中 δ_{ij} 为 Kronecker delta 函数。进而， z 的自相关矩阵满足 $R_z = E\{zz^H\} = I$ 。

设混合信号 $x(t)$ 的相关矩阵为 R_x ，根据相关矩阵的性质， R_x 存在特征值分解为：

$$R_x = Q\Sigma^2 Q^T \quad (2-7)$$

式中： Σ^2 是对角阵，相关矩阵 R_x 的特征值为 Σ^2 的对角元素 $\lambda_1^2, \lambda_2^2, \dots, \lambda_n^2$ 。 Q 是正交矩阵，它的列向量为特征值对应的标准正交特征向量。进而，白化矩阵可以表示为：

$$W = \Sigma^{-1/2} Q^T \quad (2-8)$$

只要特征值 d_i 是正的，矩阵就总是存在的。因为几乎所有自然数据都是正定的，所以其特征值总是正的。这样总可以找到白化矩阵 W 。根据 (2-6) 有：

$$R_z = E\{zz^T\} = WE\{xx^T\}W^T = WR_x W^T \quad (2-9)$$

将 (2-7) 和 (2-8) 带入 (2-9) 有：

$$R_z = \Sigma^{-1/2} Q^T (Q \Sigma^2 Q^T) (\Sigma^{-1/2} Q^T)^T = \quad (2-10)$$

因此，白化的实质就是去除信号之间的相关性。

2.3 基于盖尔圆理论的信源个数估计方法

实际工程中，信源个数通常是未知的，因此在盲分离前需要先对信号源个数进行估计。现有的源信号个数估计算法主要有：矩阵分解法、基于信息论准则的算法和基于盖尔圆准则的算法。相对于其他两种算法，基于盖尔圆准则的算法使用面更广，在低信噪比下的性能优于前两种算法，且在色噪声环境下仍能进行有效估计，本节主要介绍基于盖尔圆理论的信源个数估计算法。

Wu 和 Yang 等于 1995 年提出了基于盖尔圆理论的信号源个数估计方法^[18]，不需要知晓噪声模型，在样本数较少时仍然能进行估计。下面先介绍盖尔圆理论，然后将其应用到信号源个数估计中。

1. 盖尔圆理论

对于 $N \times N$ 维实矩阵或复矩阵 A ，设其第 i 行第 j 列元素为 a_{ij} ，第 i 行中除第 i 列外的所有元素绝对值之和为 r_i ：

$$r_i = \sum_{j=1, j \neq i}^N |a_{ij}| \quad (2-11)$$

定义第 i 个圆盘 O_i 为复平面上以 a_{ii} 为圆心，以 r_i 为半径的所有点的集合，即

$$|z - a_{ii}| \leq r_i \quad (2-12)$$

盖尔 (Gerschgorin) 已经证明^[19]，矩阵 A 的特征值包含在圆盘 O_i ， $i=1, 2, \dots, N$ 的并区间内。这个理论称为盖尔圆理论，对应的圆盘称为盖尔圆。可进一步推导盖尔圆盘具有如下性质，即若矩阵 A 的 k 个圆盘与其余圆盘不相交，则矩阵 A 恰好有 k 个特征值位于这 k 个圆盘的并区间内。

举个简单的例子进行说明。矩阵 A 由下式给出：

$$A = \begin{bmatrix} 10 & i & -i \\ -i & 5 & 0.5i \\ i & -0.5i & 4 \end{bmatrix} \quad (2-13)$$

其盖尔圆盘为 $O_1 = \{z: |z-10| \leq 2\}$ ， $O_2 = \{z: |z-5| \leq 1.5\}$ 和 $O_3 = \{z: |z-4| \leq 1.5\}$ ，如图 2.2 所示。由于 $O_2 \cup O_3$ 与 O_1 不相交，因此有两个特征值位于 $O_2 \cup O_3$ 中，另一个特征值位于 O_1 中。计算得 A 的特征值为 10.35、5.03 和 3.62，验证了这个性质。




图 2.2 式 (2-13) 矩阵对应的盖尔圆盘

定义观测数据 $x(k)$ 的协方差矩阵为

$$R = E[x(k)x(k)^H] = AR_s A^H + \sigma^2 I \quad (2-14)$$

式中: R_s 为 $s(k)$ 的协方差矩阵; σ^2 为噪声方差。根据盖尔圆理论可知, 矩阵 R 的特征值包含在圆心为 r_{ii} 、半径为 $r_j = \sum_{j, j \neq i} |r_{ij}|$ 圆盘的并区间内, r_{ij} 为 R 的第 i 行第 j 列元素。由于 R 为 Hermitian 矩阵 (满足 $R = R^H$), 其特征值和盖尔圆心均是实数, 因此在计算出盖尔圆盘后, 可以在实轴上找到特征值的可能分布。如果所有的盖尔圆盘能够形成两个不相交的并集, 分别对应信号和噪声, 较大圆盘并集包含 M 个信号特征值, 而较小圆盘并集包含余下的噪声特征值, 则较大圆盘并集中的圆盘个数就是信号源个数的估计值。

遗憾的是, 实际计算出的盖尔圆盘通常半径很大且圆心接近, 所有盖尔圆均相交, 对估计信号源个数并没有帮助。期望找到一种变换, 使得变换后的矩阵, 噪声对应的盖尔圆盘尽可能小并且远离信号对应的盖尔圆盘。

2. 信号个数估计

对 R 进行特征分解: $R = U_d D U_d^H$, 其中 $U_d = [u_1 u_2 \cdots u_M \cdots u_N]$ 为 R 的特征向量构成的 $N \times N$ 维酉矩阵, $D = \text{diag}(\lambda_1 \lambda_2 \cdots \lambda_M \cdots \lambda_N)$ 为 R 的特征值构成的对角阵。

定义

$$R = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1N} \\ r_{21} & r_{22} & \cdots & r_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ r_{N1} & r_{N2} & \cdots & r_{NN} \end{bmatrix} = \begin{bmatrix} R_1 & r \\ r^H & r_{NN} \end{bmatrix} \quad (2-15)$$

式中: R_1 为 R 的第 $(N-1)$ 阶顺序主子矩阵。记 $A = [a_1 a_2 \cdots a_{N-1}]^T$, 有

$$r = [r_{1N} r_{2N} \cdots r_{(N-1)N}]^T = [a_1 a_2 \cdots a_{N-1}]^T R_s a_n^* = A_1 R_s a_n^* \quad (2-16)$$

式中: $A = [a_1 a_2 \cdots a_{N-1}]^T$ 。将 R_1 进行特征分解有 $R_1 = U_1 D_1 U_1^H$, 其中 $U_1 = [u'_1 u'_2 \cdots u'_M \cdots u'_{N-1}]$ 和 $D_1 = \text{diag}(\lambda'_1 \lambda'_2 \cdots \lambda'_M \cdots \lambda'_{N-1})$, 分别为 R_1 的特征向量和特征值构

成的 $(N-1)(N-1)$ 维酉矩阵和对角阵。

假定 R 和 R_1 的特征值均按降序排列, 由于 R_1 和 R 是相邻的两个主子矩阵, 其特征值一定是严格交错的, 即

$$\lambda_1 \geq \lambda'_1 \geq \lambda_2 \geq \dots \geq \lambda'_M \geq \lambda_{M+1} \dots \lambda_{N-1} \geq \lambda'_{N-1} \geq \lambda_N \quad (2-17)$$

最后 $(N-1-M)$ 个特征值对应噪声, 有 $\lambda'_{M+1} = \dots = \lambda'_{N-1} = \sigma^2$ 。

构造变换矩阵 U :

$$U = \begin{bmatrix} U_1 & 0 \\ 0^T & 1 \end{bmatrix} \quad (2-18)$$

满足 $UU^H = I$ 。即 U 为酉矩阵。对协方差矩阵 R 作如下变换:

$$\begin{aligned} S = U^H R U &= \begin{bmatrix} U_1^H R_1 U_1 & U_1^H r \\ r^H U_1 & r_{NN} \end{bmatrix} = \begin{bmatrix} D_1 & U_1^H r \\ r^H U_1 & r_{NN} \end{bmatrix} \\ &= \begin{bmatrix} \lambda'_1 & 0 & \dots & 0 & \rho_1 \\ 0 & \lambda'_2 & \dots & 0 & \rho_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & \lambda'_{N-1} & \rho_{N-1} \\ \rho_1^* & \rho_2^* & \dots & \rho_{N-1}^* & r_{NN} \end{bmatrix} \end{aligned} \quad (2-19)$$

式中: $\rho_i = u_i'^H r = u_i'^H A_1 R_s a_N^*$ 。注意到 u'_i , $i = M+1, \dots, N-1$ 为 R_1 对应噪声的特征向量, 有 $R_1 u'_i = \sigma^2 u'_i = (A_1 R_s A_1^H + \sigma^2 I) u'_i$, 因此 $A_1 R_s A_1^H u'_i = 0$ 。又 A_1 为列满秩矩阵, R_s 为非奇异阵, 从而 $A_1^H u'_i = 0$ 。代入式 (2-19), 有

$$S = \begin{bmatrix} \lambda'_1 & 0 & \dots & \dots & 0 & \rho_1 \\ \vdots & & & & & \\ 0 & \lambda'_M & 0 & \dots & \rho_M \\ 0 & \dots & \sigma^2 & 0 & 0 \\ \vdots & & 0 & \ddots & \vdots \\ \rho_1^* & \rho_M^* & 0 & \dots & r_{NN} \end{bmatrix} \quad (2-20)$$

矩阵 S 和 R 具有相同的特征值, 因此 R 的特征值分布可通过分析 S 的盖尔圆盘得到。矩阵 S 的前 $(N-1)$ 个盖尔圆 O_i 的圆心为 λ'_i , 半径为 $|\rho_i|$ 。前 M 个盖尔圆对应信号, 其半径不为零, 后 $(N-1-M)$ 个盖尔圆对应噪声, 半径为零, 即变换后信号和噪声对应的盖尔圆已分开, 因此可以用来进行信号源个数估计。

将 MDL 准则中应用到的 $R^{(k)}$ 用变换后的 $S^{(k)}$ 代替, 可得到基于盖尔圆的最大似然估计。令 $z(k) = Ux(k)$, 则 $S = E[z(k)z(k)^H]$, 对数似然函数为

$$\psi_L(k) = -L \log(|S^k|) - \text{tr} \left\{ [S^{(k)}]^{-1} \hat{S} \right\} \quad (2-21)$$

式中: $\hat{S} = U^H \hat{R} U$; $S^{(k)} = U^H R^{(k)} U$ 。参照式 (2-26) 可知, $S^{(k)}$ 中元素 $\rho_{k+1} = \dots = \rho_{N-1} = 0$,

特征值满足

$$\lambda'_{k+1} = \lambda'_{k+2} = \lambda'_{N-1} = \sigma^2 = \frac{1}{N-k-1} \sum_{i=k+1}^{N-1} \lambda'_i \quad (2-22)$$

将 $S^{(k)}$ 写成分块矩阵的形式

$$S^{(k)} = \begin{bmatrix} S_{11}^{(k)} & S_{12}^{(k)} \\ S_{21}^{(k)} & S_{22}^{(k)} \end{bmatrix} \quad (2-23)$$

式中: $S_{11}^{(k)} = \text{diag}(\lambda'_1 \cdots \lambda'_k \sigma^2 \cdots \sigma^2)$; $S_{12}^{(k)} = S_{21}^{(k)} = [\rho_1 \cdots \rho_k 0 \cdots 0]^T$; $S_{22}^{(k)} = r_{NN}$ 。

将 $|S^{(k)}| = |S_{11}^{(k)}| |S_{22}^{(k)} - S_{21}^{(k)} S_{11}^{(k)-1} S_{12}^{(k)}|$, $\text{tr}[S^{(k)-1} \hat{S}] = \text{tr}[R^{(k)-1} \hat{R}] \approx N$ 代入式 (2-21), 有:

$$\psi_L(k) = L(N-1-K) \log \left[\frac{\alpha'_{N-1}(k)}{\beta'_{N-1}(k)} \right] - L \log \left(r_{NN} - \sum_{i=1}^k \frac{r_i^2}{\lambda'_i} \right) \quad (2-24)$$

其中 $\alpha'_{N-1}(k)$ 、 $\beta'_{N-1}(k)$ 分别具有如下形式:

$$\alpha'_{N-1}(k) = \prod_{i=k+1}^{N-1} l_i^{1/(N-K-1)} \quad (2-25)$$

$$\beta'_{N-1}(k) = \frac{1}{N-k-1} \sum_{i=k+1}^{N-1} l_i \quad (2-26)$$

盖尔圆似然估计的代价函为:

$$GLE(k) = \psi_L(k) + P(k, N, L) \quad (2-27)$$

其中 $p(k, N, L)$ 为修正项, 由可独立调整的参数个数决定。似然函数由函数 S 的 k 维子矩阵和相应的盖尔圆决定, 因此自由度为 $k^2 + k$ 。取 $P(k, N, L) = (k^2 + k)$ 时对应 AIC 准则 (GAIC), 取 $P(k, N, L) = (k^2 + k)(\log L)/2$ 时对应 MDL 准则 (GMDL) [20]。进一步的分析表明, GAIC 和 GMDL 均是真实值的渐进一致估计。

GAIC 和 GMDL 仍然与噪声模型相关, 为了得到在非高斯色噪声下仍然适应的方法, 下面从另一个角度出发进行考虑。

盖尔圆的半径满足

$$r_i = |\rho_i| = |u'_i A_1 R_s a_N^*| \leq |u'_i A_1| |R_s a_N^*| = \lambda |u'_i A_1| \quad (2-28)$$

其中 $\lambda = |R_s a_N^*|$ 是与 i 无关的量。根据前面的分析可知, 信号的盖尔圆半径不为零, 而噪声的盖尔圆半径为零, 因此只要确定一个合适的阈值, 就能将信号与噪声对应的盖尔圆区分开, 并根据信号对应的盖尔圆个数估计信号源个数。盖尔圆半径由 $u_i'^H A_1$ 的幅度决定, 与噪声模型及噪声大小无关, 因此该方法在非高斯色噪声及小样本数据下仍然有效。

这种方法称谓 GDE 方法, 定义相应的判断阈值为

$$GDE(k) = r_k - \frac{D(L)}{N-1} \sum_{i=1}^{N-1} r_i \quad (2-29)$$

式中: k 取值范围为 $1, 2, \dots, N-2$; $D(L)$ 是取值范围为 $0 \leq 1$ 的校正因子。噪声盖尔圆半径

随样本数 L 增加而减小，因此取 $D(L)$ 是样本数 L 的非增函数，使得样本数增大时对应的判断阈值减小。具体的判断方法为：从 $k=1$ 开始计算 $GDE(k)$ ，当 $GDE(k)$ 第一次取非正值时停止，估计源信号数为 $k-1$ 。

2.4 独立性准则

盲源分离问题所要研究的内容可以分为两个方面：分离准则和优化算法，可以简单的理解为基于某种准则下的优化问题。目前，最为常用的分离准则是独立性准则。优化算法在确定分离准则的基础上，寻找分离矩阵 U 的调整方式，使得输出信号间的独立性逐渐增大。当信号间的独立性达到最大时，就可以认为信号实现完全分离。

在统计学上，统计独立准则定义为：输出 y 的联合概率密度函数是各边缘概率密度函数的乘积，即

$$p(y) = \prod_{i=1}^M p(y_i) \quad (2-30)$$

由于 $p(y)$ 和 $p(y_i)$ 均未知，很难用式 (2-30) 对独立性做出准确的判断。对其进行改进，引申出更为直观的统计量，更加适合作为盲源分离算法中独立性判断的依据。这里主要介绍非高斯最大化准则、信息最大化准则和联合对角化准则^[21]。

2.4.1 非高斯最大化准则

根据中心极限定理，相互独立的随机变量之和近似服从高斯分布。经天线接收到的信号为多个独立信号的混合信号，混合信号的高斯性要强于单个信号源。因此，通过非高斯的最大化，即可获得独立信号，完成分离^[22]。信号的非高斯程度可用负熵来衡量，定义为任意概率密度函数和具有相同方差的高斯概率密度函数间的 $K-L$ 散度：

$$J[p(y)] = \int p(y) \log \left[\frac{p(y)}{p_G(y)} \right] dy = H_G(y) - H(y) \geq 0 \quad (2-31)$$

当且仅当 $p(y) = p_G(y)$ 时 $J[p(y)] = 0$ ， $J[p(y)]$ 值越大表示它距离高斯分布越远，非高斯程度越大。

对式 (2-31) 进行计算需要先估计 $p(y)$ ，而直接根据观测数据估计 $p(y)$ 比较繁琐。比较实用的方法是将 $p(y)$ 进行 Edgeworth 展开和 Gram-Charlier 展开后再代入进行近似求解。当 y 均值为零，且方差已归一化时，得到以下两种展开形式：

$$J(y) = \frac{1}{48} [4k_3^2 + k_4^2 + 7k_4^3 - 6k_3^2 k_4] \quad (2-32)$$

Gram-Charlier 展开：

$$J(y) = \frac{1}{48} [4k_3^2 + k_4^2 - 3k_3^4 - 18k_3^2 k_4] \quad (2-33)$$

其中 k_3 、 k_4 分别对应 y 的三阶和四阶累积量。当 k_3 较小时，以上两式变成

$$J(y) \approx \frac{1}{12} k_3^2 + \frac{1}{48} k_4^2 \quad (2-34)$$

若 $p(y)$ 偶对称，有 $k_3 = 0$ ，上式退化成

$$J(y) \approx \frac{1}{48} k_4^2 \propto k_4^2 \quad (2-35)$$

有时也可用绝对值：

$$J(y) \propto |k_4^2| \quad (2-36)$$

采用高阶统计量来近似表示概率密度函数也存在一些缺点，主要问题是，高阶统计量可能对野值 (outliers) 极其敏感。可见，高阶累积量并不是概率密度的一个鲁棒近似。因此，在某些情况下，常采用多个非多项式函数的加权和对概率密度函数进行逼近，即：

$$p(y) = p_G(y) [1 + \sum_{i=1}^N c_i F^{(i)}(y)] \quad (2-37)$$

式中： $p_G(y)$ 是具有相同方差的高斯分布； $F^{(i)}(y)$ 为满足如下条件的函数：

$$\int p_G(y) F^{(i)}(y) F^{(j)}(y) dy = \begin{cases} 0, & i \neq j \\ 1, & i = j \end{cases} \quad (2-38)$$

$$\int p_G(y) y^k F^{(i)}(y) dy = 0, k = 0, 1, 2 \quad (2-39)$$

可推导得到 $J[p(y)]$ 的计算式为

$$J(y) = \frac{1}{2} \sum_{i=1}^N E^2[F^{(i)}(y)] \quad (2-40)$$

关键在于如何选择函数 $F^{(i)}(y)$ 。一般来说，满足 (2-39) 的函数较多，为使近似性较好， $F^{(i)}(y)$ 最好选择那些使 $E[F^{(i)}(y)]$ 容易计算，且 y 增大时 $F^{(i)}(y)$ 增长速度不快于 $|y|^2$ 的函数，后一个条件是尽量使用 $E[F^{(i)}(y)]$ 对野点不敏感。

2.4.2 信息最大化准则

信息最大化方法具有以下特点：在每个输出信号 y 后面都引入一个非线性函数 $r_i = g_i(y_i)$ ，使输出 $r = [r_1, r_2, \dots, r_M]$ 的总熵量 $H(r)$ 极大^[23]，如图 2.3 所示。

输出 r 的熵定义为

$$H(r) = - \int p(r) \log(p(r)) dr \quad (2-41)$$

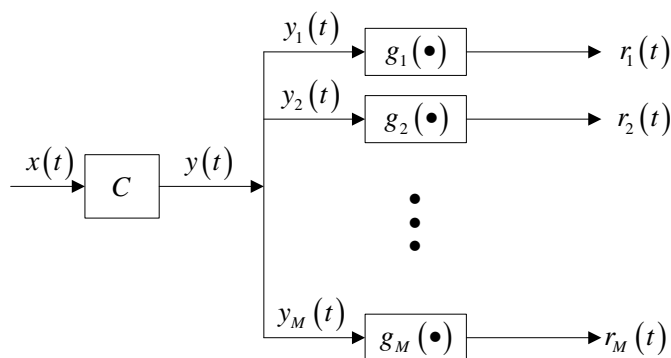


图 2.3 信息最大化法框图

根据 $r_i = g_i(y_i)$ ，有

$$\left| \frac{\partial r}{\partial y} \right| = \left| \text{diag} \left[\frac{\partial r_1}{\partial y_1}, \dots, \frac{\partial r_M}{\partial y_M} \right] \right| = \prod_{i=1}^M g'_i(y_i) \quad (2-42)$$

其中 $g'_i(y_i) = \partial g_i / \partial y_i$ 。将

$$p(r) = p(y) \left/ \left| \frac{\partial r}{\partial y} \right| \right. = p(y) \left/ \prod_{i=1}^M g'_i(y_i) \right. \quad (2-43)$$

代入到式 (2-41) 中，有

$$H(r) = - \int p(y) \log \frac{p(y)}{\prod_{i=1}^M g'_i(y)} dy \quad (2-44)$$

将 $y = Cx$ 代入上式中，有

$$\begin{aligned} H(r) &= - \int p(x) \log \frac{p(x)}{|C| \prod_{i=1}^M g'_i(y_i)} dx \\ &= -H(x) + \log |C| + \int p(x) \log \prod_{i=1}^M g'_i(y_i) dx \end{aligned} \quad (2-45)$$

当 $g'_i(y_i) = p(y_i)$ 时， $H(r)$ 最大。省略式 (2-45) 中与 C 无关的项，可构造代价函数 $\varepsilon(C)$ 如下：

$$\varepsilon(C) = \log |C| + \int p(x) \log \prod_{i=1}^M g'_i(y_i) dx \quad (2-46)$$

当 y 逼近 s 时， y 中各分量的概率密度函数 $p(y_i)$ 应接近信源 s 各分量的概率密度函数 $p(s_i)$ ，此时 $p_i(y_i)$ 应接近信源的累积分布函数，是取值 $0 \sim 1$ 的单调函数。实际中 $p(s_i)$ 一般是未知的，但实践表明 g_i 的选择并不严格，其他的单调函数如 \tanh 函数也能满足要求，只要各源信号同为超高斯信号或亚高斯信号。

2.4.3 联合对角化准则

联合对角化准则是寻找一个正交矩阵 U ，使一组数据矩阵对角化，该数据矩阵可以

是协方差矩阵或累积量矩阵^[24]，如下式所示：

$$R_x(\tau) = \{R_x(\tau_1), R_x(\tau_2), \dots, R_x(\tau_p)\} \quad (2-47)$$

根据对信号源的假设，可以得到：

$$R_s(\tau) = E[s(t)s^*(t-\tau)] = D_\tau \quad (2-48)$$

其中 D_τ 为对角矩阵，对角元素不为零。

加性噪声的自相关矩阵：

$$R_n(\tau) = E[n(t)n^*(t-\tau)] = \delta(\tau)R_n \quad (2-49)$$

根据以上各式，对于 2.1 节所述的盲源分离模型，接收信号的自相关矩阵为：

$$R_x(0) = E\{x(k)x^T(k)\} = AD_0A^T + R_n \quad (2-50)$$

$$R_x(\tau_i) = E\{x(t)x^H(t-\tau_i)\} = AD_{\tau_i}A^H, \tau_i \neq 0 \quad (2-51)$$

盲源分离的主要目的就是在没有相关阵列流行知识的情况下，辨识未知的混合矩阵 A 。从以上两式可以看出，为了抑制噪声的影响，应该使用对某些 $\tau \neq 0$ （例如 $\tau=1, 2, \dots, p$ ）的式（2-51）来辨识 A 。

从数学的角度来看，混合矩阵的辨识问题可以表述为：给定 p 个矩阵 $R_x(\tau_i)$ ， $\tau=1, 2, \dots, p$ ，求矩阵 A 和 D_{τ_i} ， $\tau=1, 2, \dots, p$ ，使得式

$$R_x(\tau_i) = AD_{\tau_i}A^H \quad (2-52)$$

这就是多个矩阵所谓的联合对角化，也称同时对角化。

2.5 主要分离方法

2.4 节介绍了几种常用的分离准则，接下来就该通过逐步取得代价函数的极值，来求得分离矩阵 C （或白化矩阵 W 和正交矩阵 U ），这就是优化方法。目前，盲源分离可分为批处理和自适应两类方法。自适应处理是随着数据的陆续到来而逐步更新处理器参数，使处理结果逐步趋向于期望的结果。信息最大化算法(Infomax)和等变自适应分解法算法(EASI)就是采用自适应的处理方式。而批处理是预先取得一组数据，对取得的数据进行一同处理，而不是随着数据的不断输入进行自适应更新。主要方法有法国学者 Cardoso 提出的四阶盲辨识算法^[25]（FOBI），建立在四阶累积量矩阵联合对角化基础上的算法（JADE），芬兰学者 Hyvarinen 提出的一种基于批处理的固定点算法（FastICA）。接下来将对上述四种盲源分离方法加以介绍，其中固定点算法将在第四章做详细介绍。

2.5.1 联合对角化算法（JADE）

联合对角化盲源分离算法最早是由 Cardoso 提出的，该算法是将输出信号的一组四阶累积量矩阵进行联合对角化，寻得分离矩阵 U ，进而实现混合信号的分离^[26]。

将观测数据 x 进行球化处理得 $z = Wx = WAs$ 。记 $V = WA$ ，由于信源 s 和白化后数据 z 的均方差为 1，且 s 中各元素相互独立， z 中元素相互正交，因此 V 是正交归一化矩阵，即 $VV^T = V^TV = I$ 。

取一个包含 N^2 个 $N \times N$ 矩阵的矩阵组，记为 M_{pq} ， $p=1,2,\dots,N$ ， $q=1,2,\dots,N$ ，定义如下：

$$M_{pq} = \begin{cases} e_p e_q^T & , p = q \\ [e_p e_q^T + e_q e_p^T] / \sqrt{2} & , p < q \\ [e_p e_q^T - e_q e_p^T] / \sqrt{2} & , p > q \end{cases} \quad (2-53)$$

式中： e_p 是除位置 p 处等于 1 外，其余位置等于 0 的 $N \times 1$ 维单位向量。当 $p = q$ 时， M_{pq} 除 (p, q) 位置处的元素等于 1 外，其余元素为 0；当 $p < q$ 时， M_{pq} 除 (p, q) 和 (q, p) 位置处的元素等于 $1/\sqrt{2}$ 外，其余元素为 0；当 $p > q$ 时， M_{pq} 在 (p, q) 和 (q, p) 位置处的元素等于 $1/\sqrt{2}$ 和 $-1/\sqrt{2}$ 外，其余元素为 0。

对每个 M_{pq} 构造关于 z 的四阶累积量矩阵 $Q_z(M_{pq})$ ，它的第 (i, j) 个元素为 $[Q_z(M_{pq})]_{ij}$ ，有

$$[Q_z(M_{pq})]_{ij} = \sum_{k=1}^N \sum_{l=1}^N \text{cum}(z_i, z_j, z_k, z_l) m_{kl} \quad (2-54)$$

式中： $\text{cum}(z_i, z_j, z_k, z_l)$ 是 z 的四阶累积量； m_{kl} 为 M_{pq} 的第 (k, l) 个元素。将 $z = Vs$ 代入式 (2-54)，记 $V = [v_1, v_2, \dots, v_N]$ ， $v_m = [v_{1m}, v_{2m}, \dots, v_{Nm}]^T$ ，有

$$\begin{aligned} [Q_z(M_{pq})]_{ij} &= \sum_{k,l} m_{kl} \text{cum} \left[\sum_{r_1=1}^N v_{r_1 i} s_{r_1}, \sum_{r_2=1}^N v_{r_2 j} s_{r_2}, \sum_{r_3=1}^N v_{r_3 k} s_{r_3}, \sum_{r_4=1}^N v_{r_4 l} s_{r_4} \right] \\ &= \sum_{k,l,r_1,r_2,r_3,r_4} m_{kl} [v_{r_1 i} v_{r_2 j} v_{r_3 k} v_{r_4 l} \text{cum}(s_{r_1} s_{r_2} s_{r_3} s_{r_4})] \end{aligned} \quad (2-55)$$

由于各信源相互独立，因此仅当 $r_1 = r_2 = r_3 = r_4 = r$ 时， $\text{cum}(s_{r_1}, s_{r_2}, s_{r_3}, s_{r_4})$ 不为零，等于 $k_4(s_r)$ 。代入上式，有

$$[Q_z(M_{pq})]_{ij} = \sum_{k,l,r} m_{kl} [v_{ri} v_{rj} v_{rk} v_{rl} k_4(s_r)] \quad (2-56)$$

用 (2-56) 来计算 $Q_z(M_{pq})v_m$ 第 i 个元素为

$$\begin{aligned} [Q_z(M_{pq})v_m]_i &= \sum_j [Q_z(M_{pq})]_{ij} v_{jm} \\ &= \sum_{k,l,r,j} m_{kl} v_{ri} v_{rj} v_{rk} v_{rl} k_4(s_r) v_{jm} \\ &= \sum_{k,l,r} m_{kl} v_{ri} v_{rk} v_{rl} k_4(s_r) \delta_{rm} \end{aligned}$$

$$= k_4(s_m) \sum_{k,l} m_{kl} v_{mi} v_{mk} v_{ml} \quad (2-57)$$

上式用到了 V 的正交归一性质。当 $p=q$ 时，有 $m_{kl} = \delta_{kp} \delta_{lp}$ ，代入上式，有

$$[Q_z(M_{pq})]_{ii} = k_4(s_m) v_{mi}^2 \quad (2-58)$$

将 (2-58) 写成矩阵形式，即 $Q_z(M_{pq})v_m = k_4(s_m)v_{mp}^2 v_m$ ，这表明 $k_4(s_m)v_{mp}^2$ 和 v_m 分别是 $Q_z(M_{pq})$ 的特征值和特征向量，从而 $Q_z(M_{pq})$ 可对角化，即

$$Q_z(M_{pq}) = V \text{diag}[k_4(s_1)v_{1p}^2, k_4(s_2)v_{2p}^2, \dots, k_4(s_N)v_{Np}^2]V^T \quad (2-59)$$

当 $p < q$ 时，同理可证明 $Q_z(M_{pq})$ 可对角化，即

$$Q_z(M_{pq}) = V \left\{ \sqrt{2} \text{diag}[k_4(s_1)v_{1p}v_{1q}, k_4(s_2)v_{2p}v_{2q}, \dots, k_4(s_N)v_{Np}v_{Nq}] \right\} V^T \quad (2-60)$$

当 $p > q$ 时， $Q_z(M_{pq}) = 0$ ，无需考虑。

式 (2-59) 与式 (2-60) 表明， V 阵能将矩阵组 $Q_z(M_{pq})$ ， $p \leq q$ 对角化，因此只要找到正交阵 V ，使得矩阵 $Q_z(M_{pq})$ 联合对角化，那么根据 V 就可求得分离结果：

$$\begin{cases} \hat{A} = W^T V, \hat{B} = \hat{A}^{-1} = V^T W \\ y = Bx = V^T Wx = V^T z \end{cases} \quad (2-61)$$

综上所述，将联合对角化算法的计算步骤概括如下：

- (1) 计算白化矩阵 W ，获得白化后的信号 z ；
- (2) 按式 (2-53) 构造 $N(N+1)/2$ 个矩阵 M_{pq} ， $p \leq q$ ，根据数据 z 由 $Q_z(M_{pq})$ 的定义式计算出 $Q_z(M_{pq})$ ；
- (3) 寻找使得 $Q_z(M_{pq})$ 联合对角化的正交阵 V ；
- (4) 按式 (2-61) 计算分离矩阵与分离后的信号；

上述计算步骤的关键是对矩阵 $Q_z(M_{pq})$ 进行联合对角化。为了衡量 $V^T Q_z(M_{pq}) V$ 的非对角化程度，用该矩阵中非对角元素的平方和来度量，即

$$J(V) = \sum_{i=1}^N \sum_{j=1, j \neq i}^N \left[\left[V^T Q_z(M_{pq}) V \right]_{ij} \right]^2 \quad (2-62)$$

上式也称为该矩阵的 Off 函数。联合对角化的代价函数可等价写成

$$J(V, \Lambda(M_{pq})) = \sum_{p=1}^N \sum_{q=p}^N \left\| \Lambda(M_{pq}) - V^T Q_z(M_{pq}) V \right\|^2 \quad (2-63)$$

从这一代价函数出发，Cardoso 等人给出了近似联合对角化的 Jacobi 算法，这一算法是对单个 Hermitian 矩阵进行对角化的 Jacobi 算法的推广，基本思想是使用一连串的成对 Givens 旋转来使式 (2-63) 达到最小。文献[16]对多个矩阵的联合对角化方法问题进行了较为详细的阐述。

JADE 算法对超高斯信号和亚高斯信号均能分离，具有分离性能好和适应性强等优点。

点，是一种经典的批处理算法。但与此同时，由于 JADE 算法需要对多个矩阵进行联合对角化，所以当信号个数增多的时候，算法计算量和存储量将呈现非线性的增长，对硬件的计算能力和存储空间有一定的要求。

2.5.2 信息最大化算法 (Infomax)

信息最大化是一种典型的自适应处理算法。自适应处理算法通常先根据分离矩阵 C 来确定一个目标函数 ε 。通过对分离矩阵 C 的逐步调节，使 ε 达到极小（或极大）。沿着正梯度方向 $\nabla \varepsilon(C)$ 来调节 C ，可以使 ε 达到极大。沿着负梯度方向 $-\nabla \varepsilon(C)$ 来调节 C ，可以使 ε 达到极小。以极大为例更新公式如下：

$$C(k+1) = C(k) + \mu_k \nabla(C(k)) \quad (2-64)$$

基于信息最大化准则的 Infomax 算法是一种经典的自适应处理算法，自提出后受到了很多学者的关注。2.4.3 小节已经推导了相应的代价函数，即

$$\varepsilon(C) = \log|C| + \int p(x) \log \prod_{i=1}^M g'_i(y_i) dx \quad (2-65)$$

改写成如下形式：

$$\varepsilon(C) = \log|C| + \sum_{i=1}^M E_x [\log g'_i(y_i)] \quad (2-66)$$

式中： $E_x[\square]$ 指以 $p(x)$ 为概率密度函数的均值。为了满足实时性需求，将上式中的统计均值 $E_x[\square]$ 用单样本的瞬时值代替，这就是随机梯度法，即

$$\varepsilon(C) = \log|C| + \sum_{i=1}^M \log g'_i(y_i) \quad (2-67)$$

下面计算 $\varepsilon(C)$ 的梯度 $\nabla \varepsilon(C)$ 。对上式右边第一项和第二项分别求导，有

$$\frac{\partial \log|C|}{\partial C} = \frac{1}{|C|} \frac{\partial |C|}{\partial C} = C^{-T} \quad (2-68)$$

$$\frac{\partial}{\partial c_{ij}} \sum \log g'_i(y_i) = \frac{g''_i(y_i)}{g'_i(y_i)} \frac{\partial y_i}{\partial c_{ij}} = \frac{g''_i(y_i)}{g'_i(y_i)} x_j \quad (2-69)$$

式中： c_{ij} 为矩阵 C 第 i 行第 j 列元素。

将式 (2-68) 和 (2-69) 代入 (2-67) 中，得

$$\nabla \varepsilon(C) = C^{-T} - \psi(y) x^T \quad (2-70)$$

其中， $\psi(y)$ 由下式决定：

$$\psi(y) = - \left[\frac{g''_1(y_1)}{g'_1(y_1)}, \frac{g''_2(y_2)}{g'_2(y_2)}, \dots, \frac{g''_M(y_M)}{g'_M(y_M)} \right]^T \quad (2-71)$$

从而得到 $C(k)$ 的更新公式为

$$C(k+1) = C(k) + \mu_k [C(k)^{-T} - \psi(y(k)) x(k)^T] \quad (2-72)$$

式(2-72)中出现了 $C(k)^{-T}$ ，需要对矩阵求逆，逆矩阵的求解过程计算量相对较大并且不够稳定。基于以上两个原因，Amari提出了自然梯度法^[27]。常规的随机梯度计算的是欧几里得空间的最陡下降方向，而代价函数 $\varepsilon(C)$ 是曲面，对应的是黎曼空间。在黎曼空间中，最陡下降方向是自然梯度，而不再是常规的随机梯度。自然梯度和常规梯度的关系为

$$\tilde{\nabla}\varepsilon(C)=[\nabla\varepsilon(C)]C^TC \quad (2-73)$$

可得自然梯度下 $C(k)$ 的更新公式为

$$C(k+1)=C(k)+\mu_k\left[I-\psi(y(k))y(k)^T\right]C(k) \quad (2-74)$$

理论上，式(2-71)中的 $g'_i(y_i)$ 应取待估计信源的概率密度函数 $p(y_i)$ ，但实践证明这个要求对信源是超高斯分布还是亚高斯分布关系较大，而只要是同一类分布（超高斯或亚高斯）， g_i 的选择并不严格。对于超高斯信号，可选择 $g'_i(y_i)=\sec h^2 y_i$ ，则 $\psi_i(y_i)=-g''_i(y_i)/g'_i(y_i)=-2\tanh$ ， $\psi_i(y_i)$ 为 $\psi(y)$ 的第 i 个元素。

为了能够同时处理超高斯信号和亚高斯信号，可以采用一种能把超高斯和亚高斯都概括在内的概率分布模型，即采用扩展 Infomax 算法^[28]。

2.5.3 等变自适应分解算法（EASI）

EASI 算法需要分两步来完成自适应处理^[29]。首先自适应更新白化矩阵 W ，在采用自然梯度算法的情况下，更新公式可以写成

$$W(k+1)=W(k)-\mu_k\left[z(k)z(k)^T-I\right]W(k) \quad (2-75)$$

第二步对正交阵 U 进行自适应更新。因为 U 是正交阵，满足 $UU^T=I$ ，因此对 U 进行更新是一个约束最优化问题。2.5.2 小节中已考虑了无约束条件下代价函数 $\varepsilon(C)$ 的梯度，但在实际工作中希望直接用输出 y 来自适应调整 C ，此时 $\varepsilon(C)$ 是输出 y 的某一函数的均值，即：

$$\varepsilon(C)=E[f(y)] \quad (2-76)$$

将上式用瞬时值代替，并计算自然梯度，有

$$\tilde{\nabla}\varepsilon(C)=\frac{\partial f(y)}{\partial C}C^TC=\frac{\partial f(y)}{\partial y}\frac{\partial y}{\partial C}C^TC=f'(y)x^TC^TC=f'(y)y^TC \quad (2-77)$$

对应的更新公式为

$$\begin{aligned} C(k+1) &= C(k)-f'(y(k))y(k)^TC(k) \\ &= \left[I-f'(y(k))y(k)^T\right]C(k) \end{aligned} \quad (2-78)$$

当 U 是正交阵时，希望更新后的矩阵 $U+\delta U$ 仍然是正交阵，有

$$(U+\delta U)(U+\delta U)^T=I+\delta+\delta^T+\delta\delta^T \quad (2-79)$$

式中： δ 是矩阵形式的调整量。式 (2-79) 中忽略二阶项 $\delta\delta^T$ 后可知，要使 $U + \delta U$ 正交， δ 需满足

$$\delta + \delta^T = 0 \quad (2-80)$$

上式表明， δ 必须是斜对称的。注意到 $y = Uz$ ，无约束优化下的自然梯度具有与式 (2-77) 相同的形式，对应 $\delta = f'(y)y^T$ 。取约束优化下的 δ 为

$$\delta = \frac{f'(y)y^T - yf'(y)^T}{2} \quad (2-81)$$

可知 δ 满足斜对称条件，相应的更新方程变成

$$U(k+1) = U(k) - \mu_k \left[f'(y(k))y(k)^T - y(k)f'(y(k))^T \right] U(k) \quad (2-82)$$

如果将第二步法合并成一步，根据 $C = UW$ 及式 (2-75) 和式 (2-82)，可得 C 的更新公式如下：

$$\begin{aligned} C(k+1) = U(k+1)W(k+1) & \left\{ I - \mu_k \left[f'(y(k))y(k)^T - y(k)f'(y(k))^T \right] \right\} \\ & U(k) \left\{ I - \mu_k \left[z(k)z(k)^T - I \right] \right\} W(k) \end{aligned} \quad (2-83)$$

注意到 $y(k) = Uz(k)$ ，有下式成立：

$$U(k) \left\{ I - \mu_k \left[z(k)z(k)^T - I \right] \right\} = \left\{ I - \mu_k \left[y(k)y(k)^T - I \right] \right\} U(k) \quad (2-84)$$

将上式代入到式 (2-83) 中，并省略 μ_k 的二阶项，得

$$C(k+1) = \left[I - \mu_k H(y(k)) \right] C(k) \quad (2-85)$$

式中

$$H(y(k)) = y(k)y(k)^T - I + f'(y(k))y(k)^T - y(k)f'(y(k))^T \quad (2-86)$$

综上所述，就得到了等变自适应分解算法 (EASI)，该算法采用 (2-85) 对分离矩阵 C 进行调整求解。根据采用准则的不同， $f(y)$ 的具体形式也将不同。

为使算法具有更好的稳定性，也可采用归一化 EASI 算法，对应的 $H(y(k))$ 为

$$H(y(k)) = \frac{y(k)y(k)^T - I}{I + \mu_k y(k)^T y(k)} + \frac{f'(y(k))y(k)^T - y(k)f'(y(k))^T}{I + \mu_k \left| y(k)^T f'(y(k)) \right|} \quad (2-87)$$

2.6 盲源分离性能评价指标

为了评价算法的性能，本文使用两种评价指标，即基于信号估计的评价指标和基于混合矩阵的评价指标^[30]。

1. 基于信号估计的评价准则

定义相关系数 ρ_{ij} 来度量分离输出信号 $y_i (i=1, 2, \dots, m)$ 与源信号 $s_j (j=1, 2, \dots, n)$ 的相

关性。

$$\rho_{ij} = \sqrt{\frac{|E\{y_i * s_j\}|^2}{E\{|y_i|^2\} E\{|s_j|^2\}}} \quad i=1,2,\dots,m; j=1,2,\dots,n \quad (2-88)$$

如果 ρ_{ij} 等于零，说明第 j 个分离信号与第 i 个信号源不相关。如果 ρ_{ij} 等于 1，说明第 j 个分离信号与第 i 个信号源完全相关。一般情况下，认为的 $\rho_{ij} \geq 0.7$ 说明分离性能比较好。可以根据 ρ_{ij} 的值来评价算法的分离程度。

2. 基于混合矩阵的评价准则

定义性能指标 PI 来度量估计混合矩阵与原混合矩阵间的距离。用其估计算法分离实现的程度，从而评价分离效果。

$$PI(P) = \sum_{i=1}^n \left[\sum_{j=1}^n \frac{|P_{ij}|}{\max_k |P_{ik}|} - 1 \right] + \sum_{j=1}^n \left[\sum_{i=1}^n \frac{|P_{ij}|}{\max_k |P_{ik}|} - 1 \right] \quad (2-89)$$

其中 $P = UA = (P_{ij})_{n \times n}$ 即分离混合矩阵， PI 值越小说明矩阵 P 越接近广义置换矩阵，分离效果越好。一般认为 PI 值小于 3.7 的情况下，可以进行有效的分离。

2.7 本章小结

本章介绍了混合信号多通道盲源分离的数学框架，并对盲分离的假设条件做了严格的限定。对接收信号进行预处理可以使盲源分离问题大大简化，因此本章对预处理以及信源个数估计进行了说明。依照盲源分离的理论框架，本章挑选了其中的一些经典准则、算法进行介绍，包括广泛使用的联合对角化算法（JADE）、信息最大化算法（Infomax）和等变自适应分解算法（EASI）。为了便于对分离效果做进一步的定量分析，本章最后给出两种分离效果的评价指标。下一章将重点介绍盲源分离算法在通信侦察系统中的应用。

第3章 同频侦察信号的盲源分离技术研究

3.1 概述

独立成分分析(Independent Component Analysis, ICA)对随机信号的混合具有显著的分離能力^{[31][32]}。然而,在像雷达和通信等系统的实际应用中,经常遇到对确定信号的混合信号的分離问题,尤其是正余弦波形和脉冲。人们可能会问,ICA 是否对确定信号的盲分离也同样有效。本章将以峭度(kurt)作为信号独立性的度量,从理论上证明 ICA 可以分离确定余弦信号的混合信号。进而启发人们应用 ICA 分离复杂的正弦信号(通信信号、雷达信号)。ICA 在通信侦察领域内的应用主要是用来分离同频混合信号,所以本章将利用上一章所介绍的盲源分离算法,通过试验仿真来验证 ICA 对同频侦察信号进行分离的有效性,讨论信号源载频间隔、取样时间长度以及信噪比对盲源分离算法性能的影响,并提出基于 NI PXI 的通信侦察接收平台的设计方案。

3.2 确定正弦信号的盲源分离

ICA 迭代算法要求信号源是相互独立的随机信号并假设它们是遍历的,这样就能够用时间平均代替统计平均,进而通过推导更新加权矩阵。然而,统计平均的概念并不适应于确定信号,所以接下来的推导也就不再成立。接下来,从这一观点出发,直接以峭度的时间平均形式(TAFC)作为独立性的度量,证明以 TAFC 作为独立性的一个标准能够分离确定余弦信号的混合信号。同时也说明以 TAFC 作为确定信号独立性的度量与峭度作为随机信号独立性的度量具有相类似的性质。

3.2.1 峭度和独立性

峭度是随机变量四阶累积量的另一种叫法^[33],峭度或其绝对值已在 ICA 和相关领域被广泛地用作非高斯的度量。这里总结出峭度的一些基本特征及其与独立性的关系。定义具有零均值的随机变量的峭度为:

$$kurt(x) = E\{x^4\} - 3(E\{x^2\})^2 \quad (3-1)$$

$E\{\cdot\}$ 表示统计平均。峭度具有如下性质:

$$kurt(x_1 + x_2) = kurt(x_1) + kurt(x_2) \quad (3-2)$$

$$kurt(ax_1) = a^4 kurt(x_1) \quad (3-3)$$

其中 x_1 和 x_2 是两个相互独立的随机变量, a 为常数。为了简单起见,只讨论 $m = n = 2$ 的情况,则有:

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = A \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} \quad (3-4)$$

对混合信号进行白化, 获得白化矩阵 W 。将 x_1 、 x_2 转换成互不相关的向量 \tilde{x}_1 、 \tilde{x}_2 。如式(3-5):

$$\begin{bmatrix} \tilde{x}_1 \\ \tilde{x}_2 \end{bmatrix} = W \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = WA \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = V \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} \quad (3-5)$$

V 是正交归一化矩阵。为了对源信号进行有效的估计, 引入单位向量 u , 对 \tilde{x}_i 进行某种线性组合。估计信号 y 可用它们的内积表示:

$$y = u^T \begin{bmatrix} \tilde{x}_1 \\ \tilde{x}_2 \end{bmatrix} = u^T V \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} \quad (3-6)$$

表示该组合。这时, 所要考虑的问题可以转化为通过最大或者最小化 y 的峭度, 找到最优的向量 u_{opt} 。根据 $u^H V (u^H V)^H = 1$, 可以设:

$$u^T V = [\sin \theta \quad \cos \theta] \quad (3-7)$$

将上式带入(3-6), 得到:

$$y = \sin \theta s_1(t) + \cos \theta s_2(t) \quad (3-8)$$

利用峭度的性质, 可得到 y 的峭度:

$$kurt(y) = \sin^4 \theta kurt(s_1) + \cos^4 \theta kurt(s_2) \quad (3-9)$$

$kurt(y)$ 对 θ 求导, 可以达到最大化或者最小化 $kurt(y)$ 的目的:

$$\begin{aligned} \frac{dkurt(y)}{d\theta} &= 4 \sin^3 \theta \cos \theta kurt(s_1) \\ &\quad - 4 \cos^3 \theta \sin \theta kurt(s_2) = 0 \end{aligned} \quad (3-10)$$

在 $kurt(s_1) \neq kurt(s_2)$ 的情况下, $kurt(y)$ 在 $\cos \theta = 0$ 或 $\sin \theta = 0$ 的时候取得极值。于是可以的到 y 的值:

$$y = \pm s_1 \text{ 或 } y = \pm s_2 \quad (3-11)$$

从上面的推导看出, 通过利用最大化或者最小化 y 的峭度这一标准, 可以从混合信号 x 中分离出独立的源信号 s 。

另一方面, 如果 $kurt(s_1) = kurt(s_2) = kurt(s)$, 上面的结果就不一定总是成立。这种情况下, 峭度可以写成:

$$kurt(y) = (\sin^4 \theta + \cos^4 \theta) k(s) \quad (3-12)$$

同样对 θ 求导, 以达到最大化或者最小化 $kurt(y)$ 的目的:

$$\begin{aligned} \frac{dkurt(y)}{d\theta} &= 4(\sin^3 \theta \cos \theta - \cos^3 \theta \sin \theta) kurt(s) \\ &= 4 \cos \theta \sin \theta (\sin^2 \theta - \cos^2 \theta) = 0 \end{aligned} \quad (3-13)$$

很明显, $kurt(y)$ 在下面三个点出取得极值:

$$\sin \theta = 0 \quad (3-14)$$

$$\cos \theta = 0 \quad (3-15)$$

$$\cos^2 \theta - \sin^2 \theta = 0 \quad (3-16)$$

根据式 (3-16) 可以得到:

$$y \propto s_1(t) \pm s_2(t) \quad (3-17)$$

式 (3-17) 表明 y 分别由 $s_1(t)$ 和 $s_2(t)$ 两种成分组成, 这是唯一一种不能够分离出独立的信号源 s 的情况。

3.2.2 时间平均峭度 (TAFC)

在许多实际应用中, 用式 (3-1) 所定义的形式来估计峭度并不实际, 这是因为很难获取信号源的足够样本点。为了克服这种困难, 经常假设随机信号是遍历的, 这样就可以用时间平均来代替统计平均。如下式:

$$\overline{kurt(x)} = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T x^4(t) - 3 \left\{ \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T x^2(t) \right\}^2 \quad (3-18)$$

这里称式 (3-18) 的形式为时间平均峭度 (TAFC), 它与式 (3-1) 相对应并明确加以区分。

设信号源为两个确定的余弦信号分别表示为:

$$s_1(t) = \cos(2\pi f_1 t + \varphi_1) \quad (3-19)$$

$$s_2(t) = \cos(2\pi f_2 t + \varphi_2) \quad (3-20)$$

则混合信号 $y(t)$ 可表示为:

$$\begin{aligned} y(t) &= \sin \theta s_1(t) + \cos \theta s_2(t) \\ &= \sin \theta \cos(2\pi f_1 t + \varphi_1) + \cos \theta \cos(2\pi f_2 t + \varphi_2) \end{aligned} \quad (3-21)$$

则 $y(t)$ 的峭度可以表示为:

$$\begin{aligned} \overline{kurt(y)} &= \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T y^4(t) - 3 \left\{ \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T y^2(t) \right\}^2 \\ \overline{kurt(y)} &= \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T [\sin \theta \cos(2\pi f_1 t + \varphi_1) + \cos \theta \cos(2\pi f_2 t + \varphi_2)]^4 \\ &\quad - 3 \left\{ \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T [\sin \theta \cos(2\pi f_1 t + \varphi_1) + \cos \theta \cos(2\pi f_2 t + \varphi_2)]^2 \right\}^2 \end{aligned} \quad (3-22)$$

这里要用到三角函数求和公式:

$$\sum_{k=1}^T \sin kx = \frac{\cos \frac{x}{2} - \cos \frac{2T+1}{2} x}{2 \sin \frac{x}{2}} \quad (3-23)$$

$$\sum_{k=1}^T \cos kx = \frac{\sin \frac{2T+1}{2}x - \sin \frac{x}{2}}{2 \sin \frac{x}{2}} \quad (3-24)$$

如果源信号 $s_1(t)$ 和 $s_2(t)$ 不是同一个信号, 即 $f_1 \neq f_2$ 和 $\varphi_1 \neq \varphi_2$ 至少有一个成立, 就可以推导出下式:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T [\cos(2\pi f_1 t + \varphi_1)]^4 = \frac{3}{8}$$

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T y^2(t) = \frac{1}{2} \sin^2 \theta + \frac{1}{2} \cos^2 \theta$$

则:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T y^4(t) = \frac{3}{8} \sin^4 \theta + \frac{3}{8} \cos^4 \theta + \frac{3}{2} \sin^2 \theta \cos^2 \theta$$

所以:

$$\begin{aligned} \overline{kurt(y)} &= \frac{3}{8} \sin^4 \theta + \frac{3}{8} \cos^4 \theta + \frac{3}{2} \sin^2 \theta \cos^2 \theta - 3 \left(\frac{1}{2} \sin^2 \theta + \frac{1}{2} \cos^2 \theta \right)^2 \\ &= -\frac{3}{8} \sin^4 \theta - \frac{3}{8} \cos^4 \theta \end{aligned} \quad (3-25)$$

$$\begin{aligned} \frac{\overline{kurt(y)}}{d\theta} &= -\frac{3}{2} (\sin^3 \theta \cos \theta - \cos^3 \theta \sin \theta) \\ &= -\frac{3}{2} \cos \theta \sin \theta (\sin^2 \theta - \cos^2 \theta) = 0 \end{aligned} \quad (3-26)$$

很明显, $kurt(y)$ 在下面三个点出取得极值:

$$\sin \theta = 0 \quad (3-27)$$

$$\cos \theta = 0 \quad (3-28)$$

$$\cos^2 \theta - \sin^2 \theta = 0 \quad (3-29)$$

根据式 (3-29) 可以得到:

$$y \propto s_1(t) \pm s_2(t) \quad (3-30)$$

式(3-30)表明 y 分别由 $s_1(t)$ 和 $s_2(t)$ 两种成分组成, 这是唯一一种不能够分离出独立的信号源 s 的情况。

由 (3-27) 和 (3-28) 可以看出, 即使源信号具体相同频率, 只要相位不同, 即不是同一个信号。以峭度作为非高斯的度量的 ICA 算法仍然可以将确定信号分离出来。这极大鼓舞人们利用更广泛的 ICA 分离算法去分离复杂的正弦信号^{[34][35]}, 也为本文利用 ICA 算法分离载频相同的通信信号提供理论依据。

3.3 基于 NI PXI 通信侦察接收平台设计和开发

将盲源分离技术应用于现有的常用通信侦察接收体系。运用虚拟仪器技术理念和软件无线电技术构架，采用基于 PXI Express 高速开放式数字总线的模块化仪器设计思路，来设计和研制适用于通信侦察接收系统的软硬件平台。（PXI 是一种由美国 NI 公司研发的基于 PC 的测量和自动化平台^{[36][37]}）。

3.3.1 基于 NI PXI 的盲分离硬件接收平台

在不考虑欠定的情况下，要分离由 n 个信号混叠而成的信号至少需要采集 n 路以上的混叠信号才可能将源信号分离出来。所以接收机具有多个射频天线，每路接收天线接收进来的信号在射频处理器中进行独立的处理，然后送到基带数据处理模块进行包括盲分离在内的通信侦察数据处理任务。这里以两路接收为例来说明基于 NI PXI 的盲分离接收机的硬件架构^[38]。

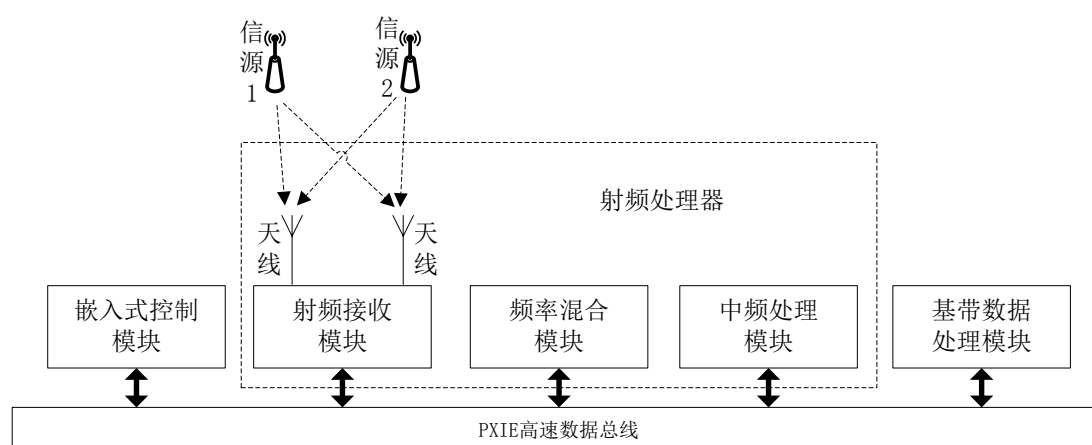


图 3.1 基于 NI PXI 的盲分离硬件接收平台

如图 3.1 所示，硬件平台由基于 PXIE 总线的嵌入式控制器、射频下变频模块、频率混合模块、中频处理模块以及基带数据处理模块组成，其中射频下变频模块、中频处理模块以及频率综合模块又构成矢量信号分析仪。

3.3.2 基于 NI PXI 的盲分离软件接收平台

通信侦察接收机软件平台所处理的数据在基带数据处理单元完成，包括。可采用模块化的设计思想，利用 PXI 自带的程序包，可使用 Labview 或者嵌入 Matlab 的方式进行编程，对数据进行实时和离线处理。

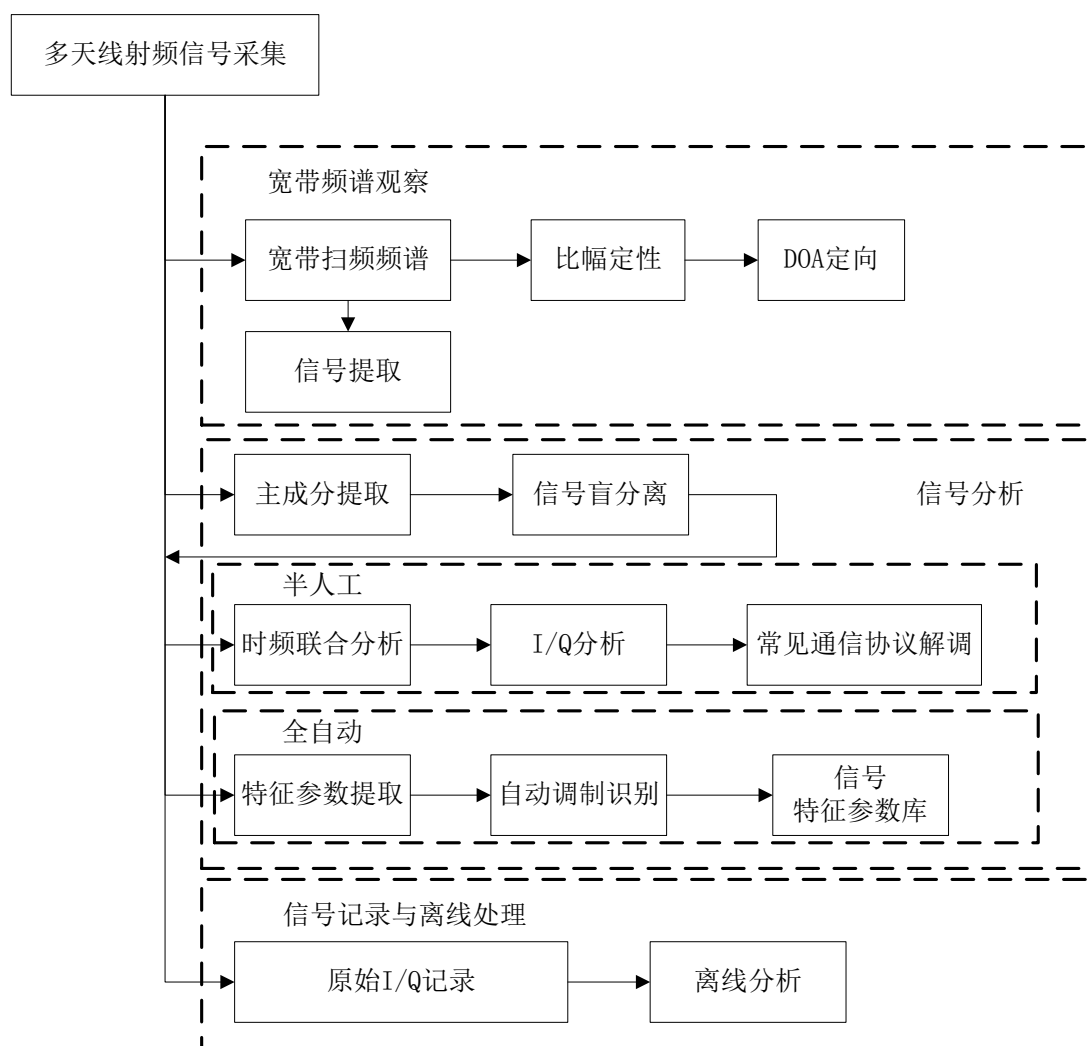


图 3.2 基于 NI PXI 的盲分离软件接收平台

通信侦察接收机软件平台所处理的数据在基带数据处理模块完成，包括宽带频谱观察、侦察信号分析和侦察信号记录和离线处理三大单元。

如图 3.2 所示，ICA 技术主要在信号分析中使用。观察频谱，通过设置门限，在有信号的频带内添加滤波器将信号提取出来。如果时频分析和自动调制识别都不能识别或者解调出侦察信号，则信号可能为多信号的混合。这时，我们可以确定混合信号个数，然后利用 ICA 技术对侦察信号进行盲分离，进而为提取侦察信号的特征和解调提供支援。

3.4 盲源分离试验仿真

为了验证本文所研究的独立成分分析方法在实际通信侦察系统中的应用，本文将利用计算机进行仿真，部分信号源的产生来源于安捷伦信号发生器。随机产生混合矩阵，对信号源进行混合。再利用盲源分离技术对时域和频域都混叠或者部分混叠的信号进行

分离。

3.4.1 盲源分离原理性试验仿真

为了验证盲源分离算法对同频混叠通信信号的分离能力,采用 FastICA 盲源分离算法,通过仿真实验证明对频域混叠的数字调制和模拟调制信号具有很好的分离效果,而且收敛速度快,具有较好的应用前景。为了更直观的验证 FastICA 分离算法在混合信号中的分离作用,采用的比较直观的单个源信号包括:AM 调制信号、FM 调制信号、MSK 调制信号,PSK 调制信号。四种信号的载波频率均为 20MHz,采样频率为 280MHz,在 20dB 的高斯白噪声下,取 4000 个采样点进行迭代。信号源的时域和频域波形分别如图 3.3 和图 3.4 所示。




图 3.3 信号源时域波形图

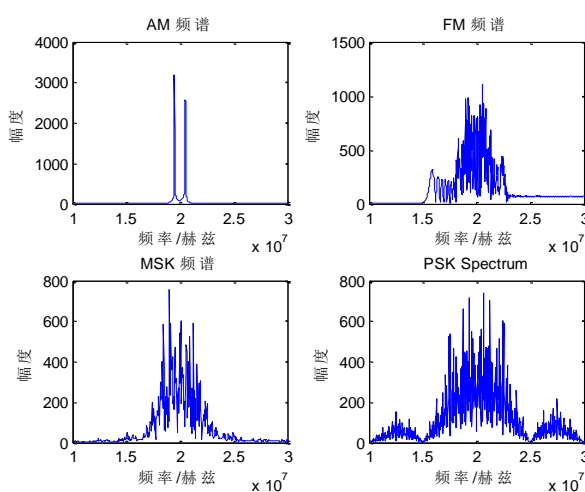


图 3.4 信号源频域波形图

从各信号源的频谱波形图可以看出，四种信号的频谱都完全重叠在一起。

混合矩阵 A 为随机产生的 6×6 矩阵(A 信道参数):

$$A = \begin{Bmatrix} 0.7842 & 0.5909 & 0.8342 & 0.6690 \\ 0.7056 & 0.4594 & 0.0156 & 0.5002 \\ 0.1093 & 0.0503 & 0.8637 & 0.2180 \\ 0.3899 & 0.2287 & 0.0781 & 0.5716 \end{Bmatrix} \quad (3-31)$$

混合后信号的时域波形如图 3.5 所示:




图 3.5 混合信号的时域波形

分离信号的时域和频域波形如图 3.6 和 3.7 所示:

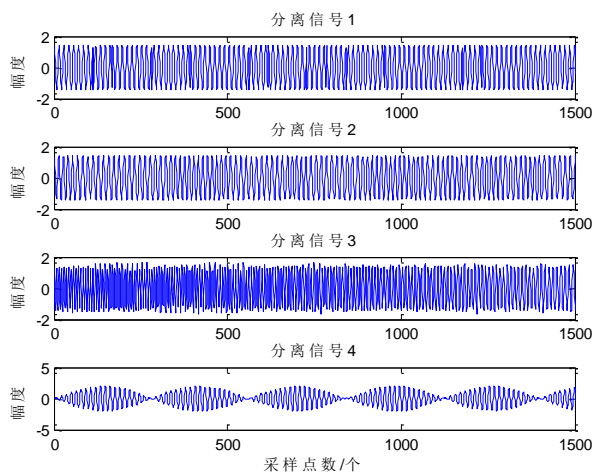


图 3.6 分离信号的时域波形

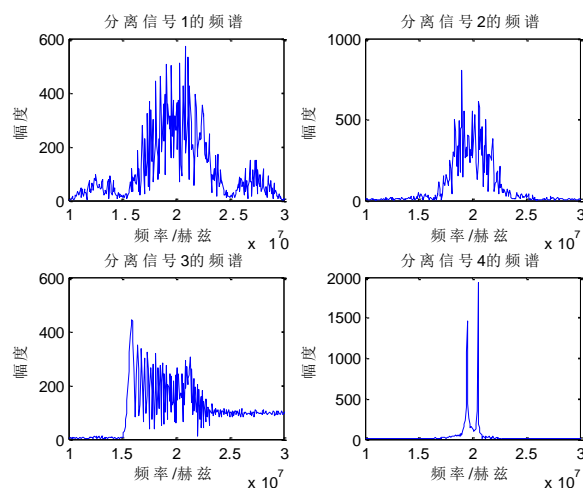


图 3.7 分离信号的频域波形

从波形上看，实现了上述 4 种频谱完全混叠的信号分离。

3.4.2 信号源载频间隔对分离性能的影响

针对 $\{2ASK, 2PSK\}$, $\{AM, FM\}$, $\{AM, 2ASK\}$ 三组信号中每两个信号在不同频谱混叠程度下 进行仿真试验。给出性能曲线和参数，说明分离效果。由于篇幅限制，这里仅以 $\{2ASK, 2PSK\}$ 为例进行说明,采用 JADE 盲源分离方法。

仿真试验一

ASK 和 PSK 的载波均为 24 兆赫兹， 两个信号的频谱完全混叠， 采样频率为 100 兆赫兹。在 20dB 的高斯白噪声下， 对两个混叠信号进行分离。

信号源的时域波形和频谱如图 3.8 和图 3.9 所示：

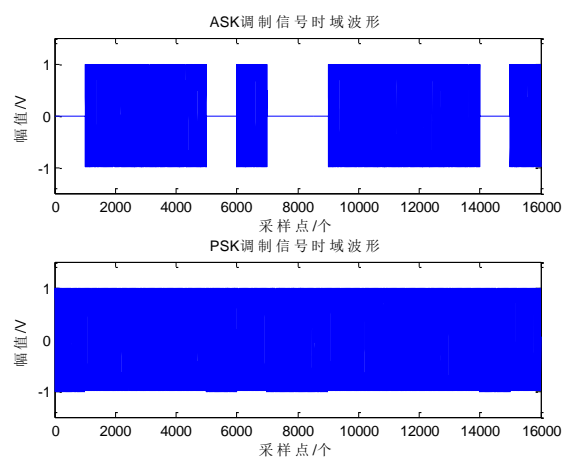


图 3.8 源信号时域波形

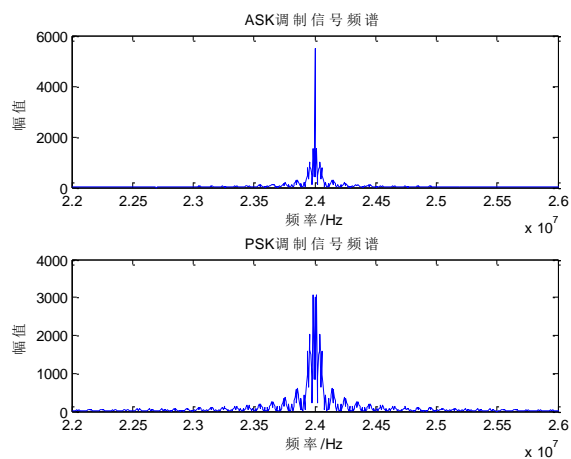


图 3.9 源信号频域波形

混合信号的时域波形如图 3.10 所示：




图 3.10 混合信号时域波形

分离信号的时域波形和频谱如图 3.11 和图 3.12 所示：




图 3.11 分离信号时域波形




图 3.12 分离信号频域波形

从波形上看，实现了上述 2 种频谱完全混叠信号的分离。

仿真试验二

固定 ASK 的载波频率，调整 PSK 的载波频率，使两个信号的频谱从完全不混叠到完全混叠。在 20dB 的高斯白噪声下，对每种 ASK 和 PSK 的频谱混叠情况进行 1000 次分离试验，计算性能参数 ρ_{ij} 和 PI 的平均值， ρ_{ij} 见图 3.13、PI 见表 3.1。值得说明的是，分离信号的顺序是不确定的，这里首先将分离信号进行调制识别，然后在进行相关系数的计算。由于本文所采用的调制识别算法在 20dB 的情况下识别率能达到 100%，所以对相关系数的求解并不产生影响。



 图 3.13 不同频率混叠下的 ρ_{ij} 值

表 3.1 20dB 信噪比下不同频率间隔 PI 指数值

频率间隔(10^5 Hz)	0	1	2	3	4	5	6	7	8	9	10
PI	0.48	0.54	0.49	0.53	0.52	0.54	0.50	0.52	0.54	0.55	0.55

从评价指标来看频率的混叠程度对通信信号的分离不带来影响。

3.4.3 信噪比对分离性能的影响

试验所采用的三个信号源分别为：AM 调制信号，MSK 调制信号，PSK 调制信号。三种信号的载波频率均为 22MHz，频谱完全重叠，如图 3.14 所示：

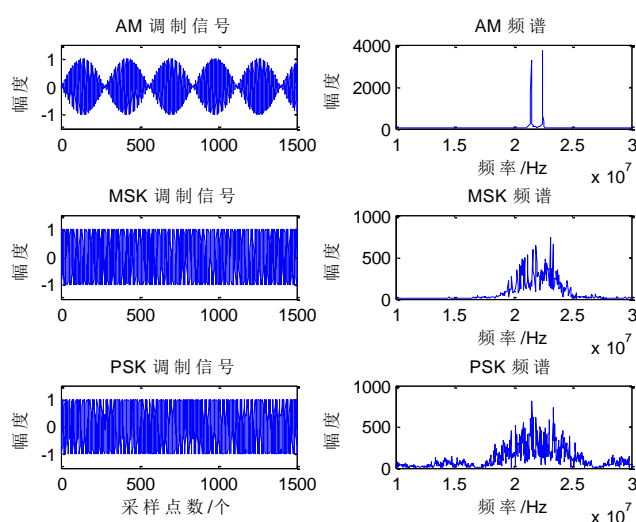


图 3.14 三种信号源时域和频域图

从图中可以看出信号频谱完全重叠。现运用本文第二章所介绍的三种盲源分离方法：JADE、FastICA、EASI 分别在不同信噪比下对上述三种信号源的混合信号进行盲分离。用性能指标 PI 来对分离混合矩阵做定量分析。信噪比的变化范围为 0dB 到 30dB，取信噪比的变化最小间隔为 1dB。在每一信噪比下，进行 100 次仿真试验，每次仿真试验均采用随机产生的混合矩阵，用三种盲源分离方法对其进行分离。计算 100 次 PI 的均值及方差分别如图 3.15 和 3.16 所示：

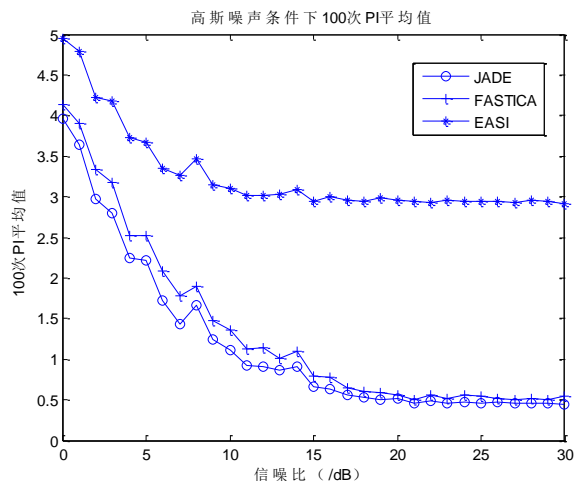


图 3.15 高斯噪声条件下 100 次 PI 的平均值

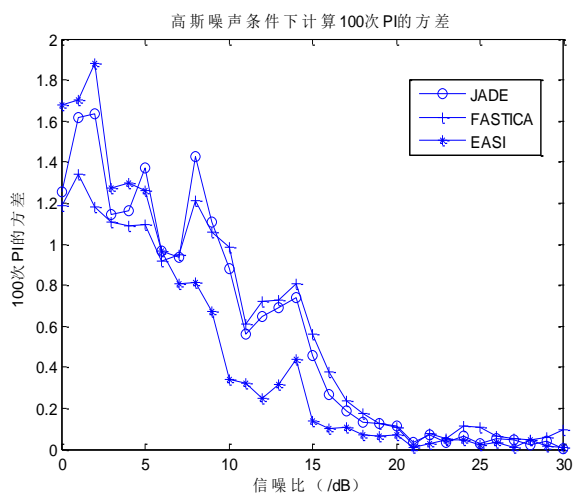


图 3.16 高斯噪声条件下 100 次 PI 方差的平均值

从图中可以看出，随着信噪比的降低，三种盲源分离的效果越来越差，并且分离效果波动性也越来越大，最终可能导致失效。并且整体来看，JADE 和 FastICA 的分离效果要强于 EASI 算法。

3.4.4 取样时间长度对分离性能的影响

不论是批处理还是自适应盲源分离方法都要保证充足的取样时间长度，以保证能够显现出各个信号所具有的独立性。在采样率 f_s 一定时，取样时间长度可以用采样点个数 N 来表示。

下面通过仿真实验来说明采样点数 N 对盲源分离性能的影响。选取三种源信号 2ASK、2PSK 和 4QAM，它们具有相同的载波频率 $f_c = 3\text{kHz}$ ，相同的码元速率 $R_c = 1000\text{Baud/s}$ 。在 30dB 的高斯白噪声条件下，以 $f_s = 10\text{kHz}$ 的采样速率进行采样。通

过随机生成矩阵将上述三种进行混合,利用 FastICA 盲源分离算法进行混合信号的分离。性能指标 PI 随采样点数 N 的变化见表 3.2。当采样点 $N=1\times 10^3$ 个时,信号源时域波形见图 3.17、混合后信号时域波形如图 3.18、分离后信号时域波形见图 3.19;当采样点 $N=5\times 10^3$ 个时,信号源时域波形见图 3.20、混合后信号时域波形如图 3.21、分离后信号时域波形见图 3.22。

表 3.2 30dB 信噪比下不同采样点数下的 PI 值

采样点数 N (10^3 个)	1	2	3	4	5	6	7
PI	3.539	3.931	3.584	3.586	0.208	0.333	0.194

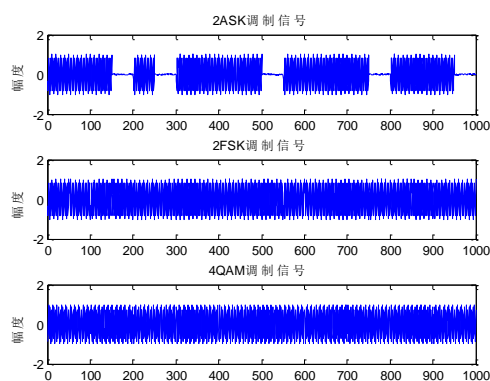


图 3.17 三种信号源时域波形图





图 3.18 混合信号时域波形图



3.19 分离信号时域波形图




图 3.20 三种信号源时域波形图

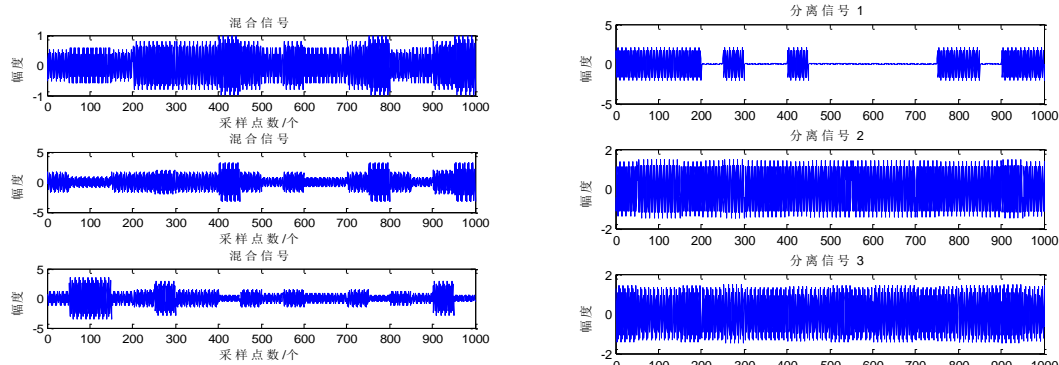


图 3.21 混合信号时域波形图

3.22 分离信号时域波形图

由表 3.2 可以看出当采样点 N 达到 5×10^3 个时, 分离性能变好。对照图 3.22 和图 3.19 同样可以发现分离效果明显改善。将性能明显改善所需的采样点个数设为 N_0 。为了使每次分离都能具有很好的分离效果, 要尽量增加盲分离迭代所需的采样点个数 N , 保证 $N \geq N_0$ 。

3.5 本章小结

在本章中, 从理论上证明了以峭度的时间平均形式 (TAFC) 作为独立性的度量可以分离确定余弦信号的混合, 尤其是同频余弦信号。启发人们利用更广泛的 ICA 分离算法去分离复杂的同频余弦信号 (通信信号、雷达信号)。将盲源分离技术应用于现有的通信侦察系统, 提出基于 NI PXI 的通信侦察接收系统的软件和硬件设计方案。最后通过试验仿真证明各信号源频谱的混叠状况并不影响分离效果。在其他条件不变的情况下, 信噪比越大, 取样时间越长, 分离效果越好。为了进一步适应通信侦察系统对分离速度和稳定性的要求, 将在下一章介绍一种基于负熵的 FastICA 算改进法。

第4章 基于负熵的 FastICA 改进算法研究

4.1 概述

独立成分分析(ICA)被认为是极具发展潜力并且有效的盲源分离方法之一。在诸多ICA算法中,快速不动点算法(FastICA)以其收敛速度快、分离效果好被广泛应用于信号处理领域。但是FastICA多采用近似牛顿迭代估计分离矩阵 U 的值,对初始权值要求较高。目前的算法初值是随机取得,这就导致运算的收敛次数相差比较大,均匀的收敛速度无法保证。另外尽管牛顿迭代具有平方或者立方的收敛速度,但是面对日益复杂的信号混叠形式,迭代速度仍需进一步提高。本章在杨俊安提出的将最速下降法与牛顿迭代算法相结合的基础上^[39],进一步在牛顿迭代过程中采用部分牛顿迭代。在保证改进算法具有均匀一致的迭代速度的同时,进一步使得改进算法获得更快的迭代和收敛速度。以适应通信侦察系统对数字通信信号的分离要求。

基于负熵最大化的 FastICA 算法是以负熵最大作为一个搜寻方向,也就是使 $U^T x$ 具有最大的非高斯性,实际上就是寻求最优分离矩阵 U 的过程,其算法框图如图 4.1 所示:




图 4.1 FastICA 算法框图

4.2 改进的基于负熵的 FastICA 算法

4.2.1 基于负熵的 FastICA 算法

Hyvarinen 等人最先提出了 FastICA 算法^[40],采用批处理的方式,快速迭代寻找出最优解。算法将高维数据沿某一个特定的方向投影到低维空间来研究高维数据的结构,每次投影后将所得结果从原数据中去除后再沿另一方向投影进行下一轮提取。

用向量 w_i 表示第 i 次投影时的投影方向,则信号分离模型为

$$y_i = w_i^T x \quad (4-1)$$

式中 y_i 是提取的第 i 个分离信号。投影方向 w_i 应选择使投影后数据间独立性最大的方向。根据大数定理,多个独立相互变量之和近似服从高斯分布。因此,为了从混合信号中提

取出独立的单个信号，应当使分离信号的非高斯性达到最大。根据非高斯性的度量不同，FastICA 算法有基于四阶累积量、基于负熵最大两种形式。由于负熵的鲁棒性更好一些，因此在本节中考虑负熵作为非高斯性的度量。

由 2.4 节可知，可将概率密度函数 $p(y)$ 展开成式 (2-31) 所示的多个非多项式函数的加权和形式。通常取 N 等于 1 和 2，即取函数 $F^{(1)}(y)$ 和 $F^{(2)}(y)$ ， $F^{(1)}(y)$ 用来表示概率密度函数的非对称性， $F^{(2)}(y)$ 用来表示在原点左右的双峰性。此时负熵可按下式进行计算：

$$J(y) \approx \omega_1 \left\{ E[F^{(1)}(y)] \right\}^2 + \omega_2 \left\{ E[F^{(2)}(y)] - E[F^{(2)}(v)] \right\}^2 \quad (4-2)$$

ω_1 和 ω_2 均为正常数， v 是均值为零的高斯随机变量，与 y 具有相同的方差。当概率密度函数 $p(y)$ 对称时，上式简化成

$$J(y) = \left\{ E[F^{(2)}(y)] - E[F^{(2)}(v)] \right\}^2 \quad (4-3)$$

FastICA 的处理分两步：首先对数据进行白化，即 $z = Wx$ ，然后对信号进行提取，即寻找投影向量 u_i ，使 $y_i = u_i^T z$ 。以式 (4-3) 为无约束下的代价函数，结合 $\|u_i\|^2 = 1$ ，形成的约束优化函数为

$$J(y) = \left\{ E[F^{(2)}(y)] - E[F^{(2)}(v)] \right\}^2 + \beta/2 (\|u_i\|^2 - 1) \quad (4-4)$$

式中： β 为常数。式 (4-4) 对 u_i 求导，有

$$\frac{\partial J(y_i)}{\partial u_i} = \gamma E[zf(u_i^T z)] + \beta u_i \quad (4-5)$$

式中：标量 $\gamma = \left\{ E[f^{(2)}(y)] - E[F^{(2)}(v)] \right\}$ 表征了信号 y_i 的高斯性，若对源信号的高斯性有先验信息，则可以取 γ 等于 1 或 -1 简化公式。函数 $f(y)$ 是 $F^{(2)}(y)$ 的导数，称之为激活函数。通常对于超高斯信号，取

$$F^{(2)}(y) = \frac{1}{\alpha} \log \cosh(\alpha y), \quad f(y) = \tanh(\alpha y) \quad (4-6)$$

对于亚高斯信号，取

$$F^{(2)}(y) = \frac{1}{4} y^4, \quad f(y) = y^3 \quad (4-7)$$

在对代价函数进行优化时，FastICA 采用了数值计算中的一种著名算法，即固定点算法。基本思想是：如果求方程 $f(x) = 0$ 的根 $x = a$ ，将 $f(x)$ 写成 $x = g(x)$ 的形式，则当 $x = a$ 时，有 $a = g(a)$ ，表明 $x = a$ 的映射 $g(x = a)$ 仍是 a ，即是固定点映射，因而得名。可采用迭代方法对 $f(x)$ 求解，如 $x(k+1) = g(x(k))$ ， k 为迭代信号。牛顿迭代也属于此类方法，迭代方程为 $x(k+1) = x(k) - f(x(k))/f'(x(k))$ 。

进入稳态时，式 (4-5) 所示的导数应为零，即

$$\gamma E[z f(u_i^T z)] + \beta u_i = 0 \quad (4-8)$$

对式 (4-8) 采用牛顿迭代法求解, 迭代公式为

$$u_i(k+1) = u_i(k) - \frac{E[z f(u_i^T(k)z)] + \beta u_i(k)}{E[zz^T f(u_i^T(k)z)] + \beta} \quad (4-9)$$

注意到 z 是白化后的数据, 近似有

$$E[zz^T f(u_i^T(k)z)] \approx E[zz^T] E[f'(u_i^T(k)z)] = E[f'(u_i^T(k)z)] \quad (4-10)$$

从而, 式 (4-9) 可简化成

$$u_i(k+1) = u_i(k) - \frac{E[z f(u_i^T(k)z)] + \beta u_i(k)}{E[f'(u_i^T(k)z)] + \beta} \quad (4-11)$$

将式上式两边左乘 $E[f'(u_i^T(k)z)] + \beta$ 并化简, 可得到如下的固定点算法:

$$\begin{cases} u_i(k+1) = E[z f(u_i^T(k)z)] - E[f'(u_i^T(k)z)] u_i(k) \\ u_i(k+1) = \frac{u_i(k+1)}{\|u_i(k+1)\|} \end{cases} \quad (4-12)$$

值得注意的是, 对多个源信号进行提取时, 原则上只需要选取不同的 $u_i(0)$, 运行式 (4-12) 所示的迭代即可, 但为了避免新提取的信号与之前提取过的信号有所重复, 需在每一次迭代前对 u_i 进行正交化, 把已提取的分量去掉。由于 U 是正交阵, 因而可以采用 *Gram-Schmidt* 正交来实现。

综上, 基于负熵的 FastICA 算法可以通过以下步骤来完成:

- (1) 对数据进行中心化, 然后进行白化, 使 $z = Wx$;
- (3) 任意取 $u_i(0)$, 要求 $\|u_i(0)\| = 1$ (i 为当前提取的源信号序号);
- (4) 迭代, $u_i(k+1) = E[z f(u_i^T(k)z)] - E[f'(u_i^T(k)z)] u_i(k)$;
- (5) 正交化, $u_i(k+1) = u_i(k+1) - \sum_{j=1}^{i-1} \langle u_i(k+1), u_j \rangle u_j$;
- (6) 归一化, $u_i(k+1) = u_i(k+1) / \|u_i(k+1)\|$;
- (7) 如果 $|\mu_i(k+1) - \mu_i(k)| > \varepsilon$, u_i 未收敛, 回到步骤 (4);
- (8) 令 $i = i+1$, 若 $i < m$ (m 为待提取的源信号个数) 则回到步骤 (3), 否则求解完成。

FastICA 算法虽然在形式上如自适应算法一样进行迭代更新, 但实际上仍是批处理算法, 因为它的每次更新都是运用所有接收数据进行运算, 而自适应算法每次更新仅用到当前时刻或者当前时刻之前的数据。FastICA 算法比传统的 ICA 算法计算效率更高, 所以在实际中广泛使用。

4.2.2 降低 FastICA 的初值敏感度

通信侦察系统对盲源分离速度的实时和同步性要求很高，这就要求盲源分离算法具有匀称的收敛速度。上一节介绍的传统FastICA算法采用近似牛顿迭代，牛顿迭代对初始权值 μ_0 具有很高的要求。但是现有牛顿迭代算法初值是随机取得的，这就导致运算的收敛次数相差比较大，无法保证均匀一致的迭代速度。在4.2.1节中介绍的FastICA算法中， $u_i(0)$ 就是任取的，会导致上述情况的发生。数理分析表明，最速下降法能够求得较好的初值，迭代初期下降速度较快，但是算法整体收敛速度相对较慢。所以这里将两种方法结合起来，先用最速下降法求得初值，然后再用牛顿迭代使算法达到收敛，完成分离。下面介绍最速下降法。

已知基于负熵的最速算法：

$$\Delta u_i \propto \gamma E \left\{ \nabla f(u_i^T(k)z) \right\} \quad (4-13)$$

$$u_i(k+1) \leftarrow u_i(k+1) / \|u_i(k+1)\| \quad (4-14)$$

式中 $\gamma = E \left\{ F(u_i^T(k)z) \right\} - E \left\{ F(v) \right\}$ ， v 是一个标准的高斯随机变量。改进算法只在初期使用最快下降法，所以不要求出精确的近似解，为减少计算量，将 γ 简化为 $\gamma = E \left\{ F(u_i^T(k)z) \right\}$ 。至此，可以得到最速下降法的迭代步骤为：

- (1) 求球化阵 W ，使 $z = Wx$ 球化；
- (2) 设 m 为待提取的源信号个数， i 为当前提取的源信号序号；
- (3) 任意取 $u_i(0)$ ，要求 $\|u_i(0)\| = 1$ ；
- (4) 迭代， $\Delta u_i \propto \gamma E \left\{ \nabla f(u_i^T(k)z) \right\}$ ；
- (5) 正交化， $u_i(k+1) = u(k+1) - \sum_{j=1}^{i-1} \langle u_i(k+1), u_j \rangle u_j$ ；
- (6) 归一化， $u_i(k+1) = u_i(k+1) / \|u_i(k+1)\|$ ；
- (7) 如果 $|\mu_i(k+1) - \mu_i(k)| > \varepsilon$ ， u_i 未收敛，回到步骤（4）；
- (8) 令 $i = i+1$ ，若 $i < m$ 则回到步骤（3），否则求解完成。

改进的算法中，将上述最速下降法与牛顿迭代结合起来。在迭代初期，首先利用最速下降法对初值不敏感和迭代初期下降速度较快的优点求出合适的初值。然后利用牛顿迭代算法在收敛点附近三次或二次的收敛速度，迅速达到收敛，完成分离。

这种改进方法很好的利用了最速下降法和牛顿迭代法的优点，使迭代次数具有较好的均匀一致性。

4.2.3 提高 FastICA 的迭代速度

通信侦察系统需要盲分离算法能够实现混合信号的快速分离，这就要求分离算法具有较高的迭代速率。虽然近似牛顿算法具有平方或者立方的收敛速度，收敛速度较快。但是面对日益复杂的信号混合形式，仍需进一步提高迭代速度。

上一节已经介绍了近似牛顿法对应的 FastICA 算法中的不动点迭代公式：

$$u_i(k+1) = u_i(k) - \frac{E[zf(u_i^T(k)z)] + \beta u_i(k)}{E[zz^T f(u_i^T(k)z)] + \beta} \quad (4-15)$$

令 $F = E[zf(u_i^T(k)z)] + \beta u_i(k)$ ，对其求梯度，称之为矩阵 $u_i(k)$ 的雅克比矩阵：

$$JF(\mu_i(k)) = \frac{\partial F}{\partial \mu_i(k)} \quad (4-16)$$

经大量研究和实验发现^{[41][42]}，在每次迭代过程中，雅克比矩阵 $JF(\mu)$ 的计算是 FastICA 最耗时的过程。为了提高迭代速率，可以通过减少雅克比矩阵的计算。有人提出在每次迭代的过程中，均使用初始矩阵 $\mu_i(0)$ 的雅克比矩阵 $JF(\mu_i(0))$ ，把这样做称称之为简化的牛顿迭代算法^[43]。这样虽然减少了雅克比矩阵的计算量，但是 $JF(\mu_i(0))$ 不随着 μ_i 的变化而变化。虽然单次迭代时间减少了，但是这样可能会导致提取单个分量的迭代次数增加，有的时候甚至会导致算法不收敛。

为了克服上述问题，本文采取在迭代过程中部分使用牛顿简化迭代法。假设已经得到 $\mu_i(k)$ ，此时我们采用简化的牛顿迭代算法，则 $\mu_i(k+1)$ 的迭代公式为：

$$\begin{cases} \mu_i^0(k) = \mu(k) \\ \mu_i^n(k) = \mu_i^{n-1}(k) - \frac{F(\mu_i^{n-1}(k))}{JF(\mu_i^0(k))}, n=1, 2, \dots, m \\ \mu_i^n(k+1) = \mu_i^m(k) \end{cases} \quad (4-17)$$

至此，只需计算一次雅克比矩阵，就相当于普通牛顿迭代法的 m 次迭代。特别的，当 $m=1$ 时，牛顿的简化迭代法退化为牛顿迭代法，通常取 $m=2$ 。

将 4.2.2 节和本节对 FastICA 的改进结合起来就得到最终的改进的基于负熵的 FastICA 算法，该算法与传统的 FastICA 算法相比，在获得均匀一致的迭代速度的同时，进一步提高迭代和收敛速度。

4.3 改进算法的计算机仿真及性能分析

选取三种时频域均混叠的数字调制信号，利用改进的基于负熵的 FastICA 算法对其进行分离。利用自行设计的数字通信模拟调制系统如图 4.2，在五种信号中选取三种作

为信号源。

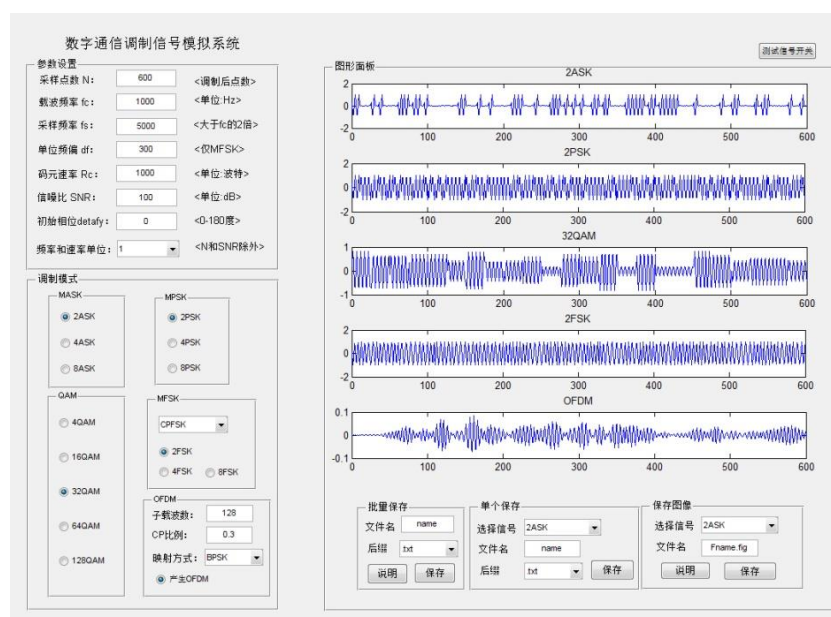


图 4.2 数字通信调制信号模拟系统

信号源 1: 2ASK 调制信号; 信号源 2: 2PSK 调制信号; 信号源 3: 2FSK 调制信号; 信号源 4: 32QAM 调制信号; 信号源 5: OFDM 调制信号。五种信号的中心频率均为 1kHz, 传码率为 1000Baud/s, 采样频率为 5kHz/s, 取 6000 个采样点进行迭代。OFDM 信号具有 128 个子载波, CP 比例为 0.3。在信噪比为 30dB 的高斯白噪声的条件下, 通过随机生成混合矩阵, 任选上述三种信号进行混合。试验仿真证明了改进算法具有很好的分离性能。

这里给出两组信号的分离图。第一组: {2ASK, 2PSK, 32QAM} 三种信号混合。信号源时域波形如图 4.3 所示, 频域波形如图 4.4 所示。随机生成混合矩阵, 混合信号波形如图 4.5 所示。利用改进算法进行分离得到分离后的信号时域和频域波形分别如图 4.6 和图 4.7 所示。

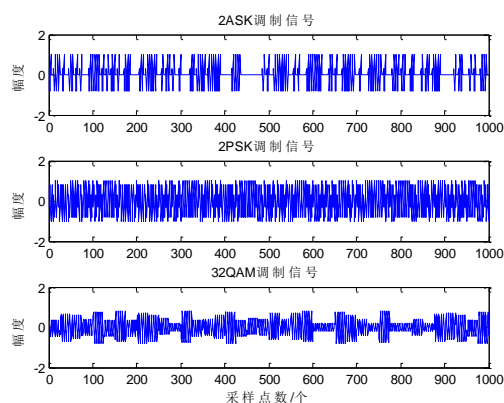


图 4.3 信号源时域波形




图 4.4 信号源频域波形




图 4.5 混合信号时域波形




图 4.6 分离信号时域波形




图 4.7 分离信号频域波形

从波形上看，实现了上述频谱完全混叠的数字通信调制信号的分离。

第二组： $\{2\text{FSK}, 2\text{PSK}, \text{OFDM}\}$ 三种信号混合。信号源时域波形如图 4.8 所示，频域波形如图 4.9 所示。随机生成混合矩阵，混合信号波形如图 4.10 所示。利用改进算法进行分离得到分离后的信号时域和频域波形分别如图 4.11 和图 4.12 所示。




图 4.8 信号源时域波形




图 4.9 信号源频域波形




图 4.10 混合信号时域波形




图 4.11 分离信号时域波形




图 4.12 分离信号频域波形

从波形上看，实现了上述频谱完全混叠的数字通信调制信号的分离。

为了进一步说明改进后的算法在迭代的稳定性和速率上具有一定的优势，下面定量的比较改进前后算法的一些参数。用不同算法对上述任意三种信号的随机混合进行 20 次分离试验，通过表 4.1 可以看出，改进算法平均收敛步数最少，收敛步数的波动范围最小。因此，改进后的算法具有更加稳定和高效的迭代速度。

表 4.1 三种算法收敛次数对比

	最少收敛步数	最多收敛步数	平均收敛步数
最速下降法	39	57	45
牛顿迭代法	12	28	15
改进算法	10	13	11

4.4 本章小结

本章提出一种基于负熵的 FastICA 的改进算法。不仅将最速下降法与牛顿迭代算法将结合，使得算法具有均匀一致的迭代速度。而且在牛顿迭代过程中采用部分牛顿迭代，使得算法具有更快的迭代和收敛速度。通信侦察系统要求信号分离具有分离速度快和同

步性高等特点。改进后的算法更加适应通侦察系统对数字通信信号分离的要求。跳频通信技术是在现代信息对抗中越来越常见，下一章将介绍一种对不同跳频网台混合的有效分离方法。

第5章 基于时频矩阵的跳频网台盲源分离方法研究

5.1 概述

跳频通信技术是在现代信息对抗日益激烈的形势下迅速发展起来的,以其独特的抗干扰和抗截获等特点在现代战争中得到了广泛的应用。不少专家预言,未来的战术通信设备非跳频电台莫属^[44]。跳频通信技术的快速发展和其在军事中的广泛应用也给通信侦察带来了新的研究课题,针对跳频网台的侦察也逐渐成为军事对抗的热点和难点。通信侦察为通信对抗提供支援和保障,旨在通过无线电侦察接收设备对敌方通信信号进行截获、分析、定位。由于对侦察目标没有任何先验知识,对跳频信号高跳频带宽、高跳频速率、低发射功率而言,要对其进行实时侦察就变得十分困难和复杂。虽然对简单和中低速跳频网台的侦察有了一定的解决办法^[45],但是对度复杂和高速跳频网台的侦察仍面临诸多挑战。通信侦察大致可分为跳频信号检测、参数估计、网台分选三个方面。如何快速而有效的从大量相互混合的跳频网台中分离出各个跳频网台,是跳频通信侦察必须要解决的关键技术之一。

盲源分离技术的发展使其在通信领域得到了广泛的应用,尤其是去除噪声、抑制干扰、多用户检测、信道均衡等方面。盲源分离理论的进一步发展也为跳频信号的分离提供了新的思路。根据不同跳频网台的相互独立性,文献[46]利用独立分量分析方法中的不动点算法(FastICA),文献[47]利用独立成分分析方法中特征矩阵联合近似对角化(JADE)算法,实现多个跳频网台的盲分离,但是这些算法对噪声的适应能力差。根据跳频信号的非平稳特性,文献[48]提出一种基于时频分布的盲源分离方法,该算法具有一定理论优势,但其只考虑时频分布中的自项区而没有考虑交叉项区。在此基础之上,本文提出一种基于时频矩阵的非正交同时对角化和非对角化盲源分离方法,该算法同时在时频分布的自项区和交叉项区上选择时频点。不仅利用自项区时频矩阵的对角化结构,也利用交叉项区时频矩阵的非对角化结构。通过增加空间时频分布矩阵的数目,从而改进分离性能。试验结果表明,该算法比独立分量分析中的特征矩阵联合近似对角化(JADE)和基于时频矩阵的正交联合对角化算法(TFJD)具有更强的噪声抑制能力。

5.2 跳频通信侦察数字化信道接收系统

合作跳频通信系统利用本地频率合成器,产生与发端频率合成器同步的跳变频率,将跳频信号转换成同一中频信号,进而可以恢复出原信号。但是对通信于侦察接系统,因为并不知道跳频图案,所以首先需要使用宽带数字接收机将全频带信号接收进来,再

进行跳频信号的参数估计和分选以及对信号的后续处理（包括信号的解跳解调或引导干扰等）^[49]。跳频通信侦察数字化信道接收系统如图 5.1 所示。

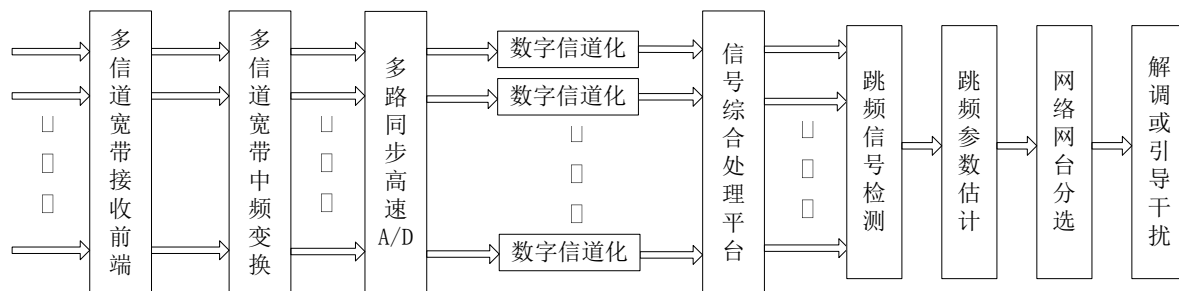


图 5.1 非合作跳频通信平台

在图 5.1 中，利用多天线对射频信号进行接收（保证天线个数多于混合跳频网台的个数），通过快速分段扫频或者多路接收的方式将很宽带宽范围内的信号接收进来。每路射频信号经过混频（可能经过多次变频）变换到同一中频，用 AD 采样将模拟信号转换为数字信号。利用数字信道化技术，将高速信号转换到多路子频带上传播，数据传输速率变低，便于后续处理^[50]。

通信侦察接收机接收到的信号可能为敌我双方多种信号的混合信号，可能包含密集的定频信号、扫频信号、噪声信号、干扰信号、各种猝发信号以及来自于多个跳频网台的跳频信号，所以对单个跳频网台的情报分析和干扰就变得更加复杂和困难。跳频网台分选是新一代通信侦察定位设备的新功能，在进行跳频网台分选之前，要通过设置门限滤除噪声信号，剔除定频、扫频、猝发信号、窄带干扰等非跳频信号。在跳频信号盲检测和估计的基础之上，将混合在一起的跳频网台分开，进而实现对敌方跳频信号的解调和干扰^[51]。

5.3 基于平滑伪魏格纳维尔分布 (SPWVD) 的时频分布矩阵

对于非平稳信号，伪魏格纳维尔分布 (Pseudo Wigner-Ville Distribution PWVD) 具有较高时间和频率分辨率，是 Cohen 类分布中较为经典的一种时频分布。对于源信号 $s(t)$ ，定义其 PWVD 为：

$$D_{WV,ss}(t, f) = \int_{-\infty}^{+\infty} s(t + \frac{\tau}{2}) s^*(t - \frac{\tau}{2}) h(\tau) \exp(-j2\pi f \tau) d\tau \quad (5-1)$$

式中 $h(\tau)$ 是平滑窗函数。平滑伪魏格纳维尔分布 (Smoothed Pseudo Wigner -Ville Distribution SPWVD) 是对伪魏格纳维尔分布的一种改进，能够很好的抑制交叉项。对于源信号 $s(t)$ ，定义其 SPWVD 为：

$$D_{ss}(t, f) = \iint g(\mu) h(\tau) s(t - \mu + \frac{\tau}{2}) s^*(t - \mu - \frac{\tau}{2}) e^{-j2\pi f \tau} d\mu d\tau \quad (5-2)$$

式中 $g(\mu)$ 和 $h(\tau)$ 是两个实的偶窗函数。信号 $s_1(t)$ 、 $s_2(t)$ 的互 SPWVD 为：

$$D_{s_1 s_2}(t, f) = \iint g(\mu) h(\tau) s_1(t - \mu + \frac{\tau}{2}) s_2^*(t - \mu - \frac{\tau}{2}) e^{-j2\pi f \tau} d\mu d\tau \quad (5-3)$$

在实际应用 SPWVD 时，需要将之离散化，以便利用 FFT 变换，其离散形式定义如下：

$$D_{ss}(n, k) = 2 \sum_{\tau=-L}^L W_N(\tau) e^{-j4\pi k \tau / N} \sum_{u=H}^H W_M(\mu) s(n + \tau - \mu) s^*(n - \tau - \mu) \quad (5-4)$$

式中 $W_N(\tau)$ 和 $W_M(\mu)$ 是长度分别为 N 和 M 的两个窗函数，其中 $N = 2L + 1$ 、 $M = 2H + 1$ 。在此基础上，矢量 $s(t)$ 的时频分布矩阵可以定义为 $D_{ss}(t, f)$ ，其中 $[D_{ss}(t, f)]_{ij} = D_{s_i s_j}(t, f)$ ， $(i, j = 1, \dots, n)$ [52][53]。

在不考虑噪声的情况下，观测信号 $x(t)$ 和信号源 $s(t)$ 的时频分布矩阵有如下关系：

$$D_{xx}(t, f) = A D_{ss}(t, f) A^H \quad (5-5)$$

式中，上标 H 表示矩阵的复共轭转置；矩阵 $D_{ss}(t, f)$ 的元素由源信号 $s(t)$ 的自分布项和互分布项构成，自分布项构成了 $D_{ss}(t, f)$ 的对角线元素，互分布项构成了 $D_{ss}(t, f)$ 的非对角线元素。

5.4 基于时频矩阵的非正交联合对角化和非对角化盲源分离

采用 SPWVD 时频矩阵的盲源分离算法的依据是：自项区和交叉项区都包含信号分离的重要信息，因此对接收到的混合信号 $x(t)$ 同时在自项区和交叉项区选择时频点，然后运用非正交联合对角化和非对角化算法求得分离信号 $y(t)$ 。

5.4.1 时频点的选择

通常在时频分析中，噪声能量均匀的分布在整个时域面上，而信号相对于噪声有更好的时频聚集性。时频聚集性是指信号的时频分布具有很好的时频局域性，或其能量在时频平面上是高度聚集的 [54]。应用聚类分析，将所有搜索点的时频分布矩阵范数的均值设置为门限值，记为 $mean(D_{xx}(t, \beta))$ 。时频分布矩阵的范数小于门限值的认为是噪声点予以滤除，大于门限值的保留 [55]。

在滤除受噪声影响较大的时频点之后，后续工作是选择保留的时频点。通过举例说明时频点的选择过程，设有两个信号源，每个信号源具有两个频率成分，其解析形式如下式：

$$s_1(t) = \exp(i2\pi f_0 t) + \exp(i2\pi f_1 t) \quad (5-6)$$

$$s_2(t) = \exp(i2\pi f_0 t) + \exp(i2\pi f_3 t) \quad (5-7)$$

应用式(5-1)，令 $h(\tau) = 1$ 、 $f_0 = f_2 = 5\text{Hz}$ 、 $f_1 = 10\text{Hz}$ 、 $f_3 = 30\text{Hz}$ 。可以得到：

$$D_{WV, s_1 s_1} = [\delta(f - 5) + \delta(f - 10)] \otimes 1_t + 2\delta(f - 7.5) \cos(10\pi t) \quad (5-8)$$

$$D_{WV, s_2 s_2} = [\delta(f - 5) + \delta(f - 30)] \otimes 1_t + 2\delta(f - 17.5) \cos(50\pi t) \quad (5-9)$$

$$D_{WV, s_1 s_2} = \delta(f - 5) \otimes 1_t + \delta(f - 7.5) \exp(i10\pi t) + \delta(f - 17.5) \exp(i50\pi t) + \delta(f - 20) \exp(i40\pi t) \quad (5-10)$$

信号 $s_1(t)$ 的自 WVD 图、信号 $s_2(t)$ 的自 WVD 图、信号 $s_1(t)$ 和 $s_2(t)$ 的互 WVD 图分别如图 5.2-图 5.4 所示。




图 5.2 信号 $s_1(t)$ 的自 WVD 图




图 5.3 信号 $s_2(t)$ 的自 WVD 图




图 5.4 信号 $s_1(t)$ 和 $s_2(t)$ 的联合 WVD 图

对照图 5.2 到图 5.4，由式(5-8)到式(5-10)发现，当两个信号存在同频成分时，时频分布矩阵将会有很特殊的结构，具体见表 5.1。

表 5.1 WVD 时频分布的频率成分

伪魏格纳维尔 时频分布	频率点/Hz					
	5	7.5	10	17.5	20	30
$D_{WV, s_1 s_1}$	有	有	有	无	无	无
$D_{WV, s_2 s_2}$	有	无	无	有	无	有
$D_{WV, s_1 s_2}$	有	有	无	有	有	无
选择机制	不做选择	不做选择	自相区	不做选择	交叉项区	自项区

如表 5.1 所示，在所有时间域上，当 $f = f_1 = 10\text{Hz}$ 时， $D_{WV, s_1 s_1} \neq 0$ 、而 $D_{WV, s_2 s_2} = D_{WV, s_1 s_2} = 0$ ；同样当 $f = f_3 = 30\text{Hz}$ 时， $D_{WV, s_2 s_2} \neq 0$ 、而 $D_{WV, s_1 s_1} = D_{WV, s_1 s_2} = 0$ 。因此，以上两类时频点只存在单个信号的自分布项，此类时频点上的时频矩阵是对角的，可以考虑采用非正交联合对角化(JD)。在所有时间域上，当 $f = 20\text{Hz}$ 时， $D_{WV, s_1 s_2} \neq 0$ ， $D_{WV, s_1 s_1} = D_{WV, s_2 s_2} = 0$ 。因此，该类时频点只存在两个信号的互分布项，此类时频点上的时频矩阵是零对角的，可以考虑采用非正交联合非对角化(JZD)。在所有时间域上，当 $f = 5\text{Hz}$ 、 7.5Hz 、 17.5Hz 时，既存在单个信号的自分布项也存在两个信号的互分布项。时频分布矩阵没有特殊的相关结构，所以不是进行信号盲分离所关心的。同样，在其他时频点上既不存在单个信号的自分布项也不存在两个信号的互时频项，不予考虑。

由以上的分析可以得出如下的结论，观测信号 $z(t)$ 的时频矩阵存在四类不同的时频点：自分布项的时频点、互分布项的时频点、既不是自分布项也不是互分布项的时频点、既是自分布项也是互分布项的时频点。前两类时频点是盲源分离的关注点。将只含有自分布项的时频点称为自项区，对在自项区上的时频矩阵采用非正交联合对角化(JD)；将只含有互分布项的时频点称为交叉项区，对在交叉项区上的时频矩阵采用非正交联合非对角化(JZD)。由于白化后的观测信号与源信号满足 $\text{Trace}\{\underline{D}_{xx}(t, f)\} = \text{Trace}\{\underline{D}_{ss}(t, f)\}$ ，故采用白化后的信号进行时频点选择。对于自相区和交叉项区的选择，本文提出以下时频点的选取策略：

$$\begin{cases} \|\Im\{\underline{D}_{xx}(t, f)\}\| > \varepsilon_1 \\ |\text{Trace}\{\underline{D}_{xx}(t, f)\}| < \varepsilon_2 \end{cases} \rightarrow \text{该时频点选入自相区(JZD)} \quad (5-11)$$

$$\begin{cases} \|\Im\{\underline{D}_{xx}(t, f)\}\| < \varepsilon_3 \\ |\text{Trace}\{\underline{D}_{xx}(t, f)\}| > \varepsilon_4 \end{cases} \rightarrow \text{该时频点选入交叉项区(JD)} \quad (5-12)$$

$\underline{D}_{xx}(t, f)$ 表示接收信号 $z(t)$ 经过白化后的 SPWVD 时频矩阵， $|\text{Trace}\{\bullet\}|$ 表示求矩阵迹的绝对值， $\|\Im\{\bullet\}\|$ 表示求矩阵虚部的欧几里得范数。 ε_1 、 ε_2 、 ε_3 、 ε_4 为阈值，适用于跳频网台分选的最佳阈值选取是一项有意义的工作，根据文献[56]-[58]，并结合经验和大量实验所得，实验中取 $\varepsilon_1=16$ 、 $\varepsilon_2=2$ 、 $\varepsilon_3=0.1$ 、 $\varepsilon_4=15$ 。

5.4.2 代价函数

传统的基于时频分析的正交联合对角化算法 (TFJD)^[59]，仅考虑信号时频分布中的自项区而不考虑交叉项区，以保证时频矩阵分布的对角结构。鉴于正交方法需经白化处理，而白化处理会引入一系列问题（如白化误差等），尤其在色噪声条件下预白化更

是无法实现，因此本文提出同时非正交联合对角化和非对角化方法（JDZD），同时利用来自于自项区和交叉项区的时频分布矩阵，建立统一的代价函数，进而改进分离性能。

既然要考虑同时联合对角化和非对角化问题，就要将两组矩阵分别考虑。为了区分起见，以自项时频点估计的自项时频矩阵记为 $D_{xx}^D(t, f)$ ，而以交叉项时频点估计的交叉项时频矩阵记为 $D_{xx}^Z(t, f)$ 。选择自项时频点时，空间时频分布中源信号和观测混合信号的时频分布函数矩阵的关系为：

$$D_{xx,i}^D = A_D D_{ss,i}^D(t, f) A_D^H \quad \forall i \in \{1, \dots, N_D\} \quad (5-13)$$

式中： $D_{ss}^D(t, f)$ 是对角阵。 A_D 为列满秩矩阵， N_D 为自项点时频矩阵的个数。选择交叉项时频点时，空间时频分布中源信号和观测混合信号的时频分布函数矩阵的关系为：

$$D_{xx,i}^Z = A_Z D_{ss,i}^Z(t, f) A_Z^H \quad \forall i \in \{1, \dots, N_Z\} \quad (5-14)$$

式中： $D_{ss}^Z(t, f)$ 是非对角的，即方阵 $D_{ss}^Z(t, f)$ 所有对角元素都为零。 A_Z 为列满秩矩阵， N_Z 为交叉项点时频矩阵的个数。JD 是只根据 $\{D_{xx,i}^D(t, f) | i \in 1, \dots, N_D\}$ 估计矩阵 A_D 和 $D_{ss,i}^D(t, f)$ ，JZD 是只根据 $\{D_{xx,i}^Z(t, f) | i \in 1, \dots, N_Z\}$ 估计矩阵 A_Z 和 $D_{ss,i}^Z(t, f)$ 。理论上存在 $A_D = A_Z = A_{ZD}$ ，所以可以采用非正交联合对角化和非对角化（JDZD），同时利用 $\{D_{xx,i}^D(t, f) | i \in 1, \dots, N_D\}$ 和 $\{D_{xx,i}^Z(t, f) | i \in 1, \dots, N_Z\}$ 估计出 A_{ZD} 。

采用经典算法解决 JD 和 JZD 问题，通过矩阵分解将上述求解过程转化为最小化下面两个代价函数：

$$J_D(A, \{\Lambda_{D,i}\}) = \sum_{i=1}^{N_D} \|D_{xx,i}^D - A_D \Lambda_{D,i} A_D^H\|^2 \quad i \in \{1, \dots, N_D\} \quad (5-15)$$

$$J_Z(A, \{\Lambda_{Z,i}\}) = \sum_{i=1}^{N_Z} \|D_{xx,i}^Z - A_Z \Lambda_{Z,i} A_Z^H\|^2 \quad i \in \{1, \dots, N_Z\} \quad (5-16)$$

式中 $\|\cdot\|$ 代表求矩阵的 Frobrnius 范数， $\{\Lambda_{D,i}\}$ 和 $\{\Lambda_{Z,i}\}$ 分别表示对角矩阵和非对角矩阵的集合。

若用 $A_D^+ (A_Z^+)$ 代表 $A_D (A_Z)$ 的广义逆矩阵，可以对式 (5-13) 和 (5-14) 做进一步变换，在 $D_{xx,i}^D (D_{xx,i}^Z)$ 的左右两边分别乘以 $A_D (A_Z)$ 和 $A_D^H (A_Z^H)$ 的逆矩阵得：

$$(A_D^+) D_{xx,i}^D (A_D^+)^H = D_{ss,i}^D(t, f) \quad \forall i \in \{1, \dots, N_D\} \quad (5-17)$$

$$(A_Z^+) D_{xx,i}^Z (A_Z^+)^H = D_{ss,i}^Z(t, f) \quad \forall i \in \{1, \dots, N_Z\} \quad (5-18)$$

因此，为了直接估计 A_D^H 和 A_Z^H 的逆矩阵，将式 (5-15) 和 (15-16) 两个代价函数改写成以下形式：

$$C_D'(B, \{\Lambda_{D,i}\}) = \sum_{i=1}^{N_D} \|B D_{xx,i}^D B^H - \{\Lambda_{D,i}\}\|^2 \quad i \in \{1, \dots, N_D\} \quad (5-19)$$

$$C_Z'(B, \{\Lambda_{Z,i}\}) = \sum_{i=1}^{N_Z} \|BD_{xx,i}^Z B^H - \{\Lambda_{Z,i}\}\|^2 \quad i \in \{1, \dots, N_Z\} \quad (5-20)$$

对 *Frobrnius* 范数里的矩阵参数采用上述酉矩阵的相乘形式，范数的大小并不改变。所以如果 A_D (A_Z) 是酉矩阵，可以推出 ($J_Z = C_Z'$)。采用 C_D' 和 C_Z' 作为代价函数将使得通过最小化代价函数 C_D' 和 C_Z' 来求解矩阵 $\Lambda_{D,i}$ 和 $\Lambda_{Z,i}$ 变得更加直接。因此，可以定义：

$$\hat{\Lambda}_{D,i} = \arg \min_{\Lambda_{D,i}} C_D'(B, \{\Lambda_{D,i}\}) \quad \forall i \in \{1; \dots N_D\} \quad (5-21)$$

$$\hat{\Lambda}_{Z,i} = \arg \min_{\Lambda_{Z,i}} C_Z'(B, \{\Lambda_{Z,i}\}) \quad \forall i \in \{1; \dots N_Z\} \quad (5-22)$$

进而可以写成：

$$\hat{\Lambda}_{D,i} = \text{Diag} \{BD_{xx,i}^D B^H\} \quad \forall i \in \{1; \dots N_D\} \quad (5-23)$$

$$\hat{\Lambda}_{Z,i} = \text{Offdiag} \{BD_{xx,i}^Z B^H\} \quad \forall i \in \{1; \dots N_Z\} \quad (5-24)$$

以方阵 $C = (C_{i,j})$ 来定义矩阵运算符号 $\text{Diag} \{\square\}$ 和 $\text{Offdiag} \{\square\}$ 有, $(\text{Diag} \{C\})_{i,j} = \delta_{i,j} C_{i,j}$ 和 $(\text{Offdiag} \{C\})_{i,j} = (1 - \delta_{i,j}) C_{i,j}$ 。将式 (5-23) 应用到式 (5-19)，可以得到：

$$\begin{aligned} C_D'(B, \{\hat{\Lambda}_{D,i}\}) &= \sum_{i=1}^{N_D} \|BD_{xx,i}^D B^H - \{\hat{\Lambda}_{D,i}\}\|^2 \\ &= \sum_{i=1}^{N_D} \|BD_{xx,i}^D B^H - \text{Diag} \{BD_{xx,i}^D B^H\}\|^2 \\ &= \sum_{i=1}^{N_D} \|\text{Offdiag} \{BD_{xx,i}^D B^H\}\|^2 \stackrel{\text{def}}{=} C_D(B) \end{aligned} \quad (5-25)$$

同样的，将式 (5-24) 应用到式 (5-20)，可以得到：

$$\begin{aligned} C_Z'(B, \{\hat{\Lambda}_{Z,i}\}) &= \sum_{i=1}^{N_Z} \|BD_{xx,i}^Z B^H - \{\hat{\Lambda}_{Z,i}\}\|^2 \\ &= \sum_{i=1}^{N_Z} \|BD_{xx,i}^Z B^H - \text{Offdiag} \{BD_{xx,i}^Z B^H\}\|^2 \\ &= \sum_{i=1}^{N_Z} \|\text{Diag} \{BD_{xx,i}^Z B^H\}\|^2 \stackrel{\text{def}}{=} C_Z(B) \end{aligned} \quad (5-26)$$

为了通过同时最小化 $C_D(B)$ 和 $C_Z(B)$ 求到矩阵 B ，这里引入新的联合代价函数：

$$C(B) = \alpha C_D(B) + (1 - \alpha) C_Z(B) \quad \alpha \in [0, 1] \quad (5-27)$$

5.4.3 优化算法

为了对 $C(B)$ 做进一步的推导，对 $C_D(B)$ 和 $C_Z(B)$ 进行改写：

$$C_D(B) = \sum_{i=1}^{N_D} \|\text{Offdiag} \{BD_{xx,i}^D B^H\}\|^2$$

$$\begin{aligned}
 &= \sum_{i=1}^{N_D} \sum_{l=1}^N \sum_{\substack{k=1 \\ k \neq l}}^N |b_l D_{xx,i}^D b_k^H|^2 \\
 &= \sum_{l=1}^N b_l \sum_{i=1}^{N_D} D_{xx,i}^D \left(\sum_{\substack{k=1 \\ k \neq l}}^N b_k^H b_k \right) (D_{xx,i}^D)^H b_l^H \\
 &= \sum_{l=1}^N b_l R_D(B_l) b_l^H
 \end{aligned} \tag{5-28}$$

其中:

$$R_D(B_l) = \sum_{i=1}^{N_D} D_{xx,i}^D \left(\sum_{\substack{k=1 \\ k \neq l}}^N b_k^H b_k \right) (D_{xx,i}^D)^H \tag{5-29}$$

$$\begin{aligned}
 C_Z(B) &= \sum_{i=1}^{N_Z} \left\| \text{Diag} \{ B D_{xx,i}^Z B^H \} \right\|^2 \\
 &= \sum_{i=1}^{N_D} \sum_{l=1}^N |b_l D_{xx,i}^Z b_l^H|^2 \\
 &= \sum_{l=1}^N b_l \sum_{i=1}^{N_Z} D_{xx,i}^Z (b_l^H b_l) (D_{xx,i}^Z)^H b_l^H \\
 &= \sum_{l=1}^N b_l R_Z(b_l) b_l^H
 \end{aligned} \tag{5-30}$$

其中:

$$R_Z(B_l) = \sum_{i=1}^{N_Z} D_{xx,i}^Z (b_l^H b_l) (D_{xx,i}^Z)^H \tag{5-31}$$

所以, 代价函数 $C(B)$ 可以进行进一步推导:

$$\begin{aligned}
 C(B) &= \alpha C_D(B) + (1-\alpha) C_Z(B) \\
 &= \alpha \sum_{l=1}^N b_l R_D(B_l) b_l^H + (1-\alpha) \sum_{l=1}^N b_l R_Z(b_l) b_l^H \\
 &= \alpha \sum_{l=1}^N b_l R_D(B_l) b_l^H + (1-\alpha) \sum_{l=1}^N b_l R_Z(b_l) b_l^H
 \end{aligned} \tag{5-32}$$

令 $R_l(B) = \alpha R_D(B_l) + (1-\alpha) R_Z(b_l)$, 则有:

$$C(B) = \sum_{l=1}^N b_l R_l(B) b_l^H \tag{5-33}$$

$C(B)$ 的最小化可以逐行的实现^[60], 也可以采用 Givens 旋转, 进而估计酉阵 B 。

5.4.4 分离步骤

综上所述, 基于 SPWVD 时频矩阵的 JDZD 盲分离算法的过程如图 5.5 所示。

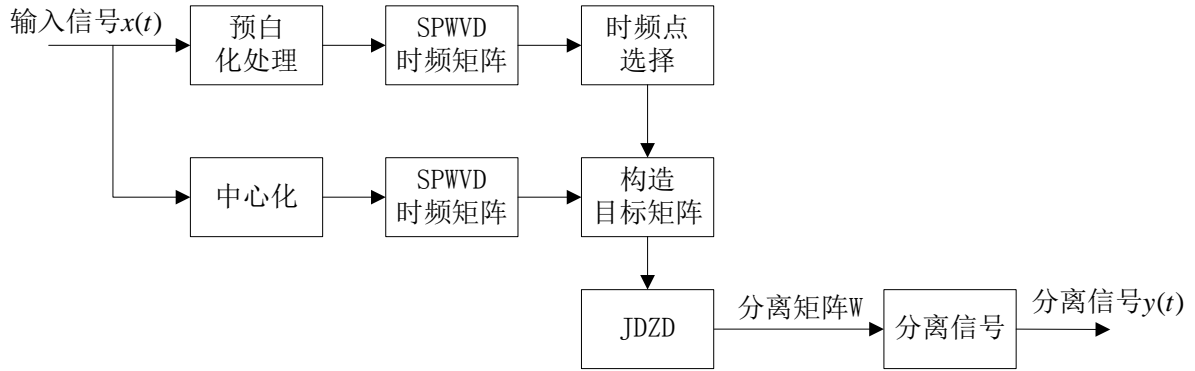


图 5.5 基于时频矩阵的 JDZD 盲源分离算法框图

对图 5.5 进行文字描述，可以概括为如下基本步骤：

- (1) 对接收信号进行预处理，包括白化、中心化、主成分提取、估计噪声方差 σ^2 。
- (2) 将白化后的信号转化为基于 SPWVD 的时频矩阵，利用式(5-11)和(5-12)对其落在自项区和交叉项区的时频点进行选择。
- (3) 利用中心化后的接收信号生成基于 SPWVD 的时频矩阵，结合(2)中选择出来的时频点，构造出目标矩阵集合。
- (4) 对所选时频矩阵集合进行非正交联合对角化和非对角化，估计酉阵 \mathbf{B} （对应线性瞬时混合模型中的 \mathbf{C} ）。
- (5) 以 $\hat{s}(t) = \mathbf{B}\mathbf{x}(t)$ 估计信号源。

5.5 试验仿真

用 Matlab 随机生成的 3×4 阶的混合矩阵，对每路接收信号加以 10dB 的高斯白噪声，应用本文提出的算法对三个信号源的混合跳频信号进行盲源分离，重构出源信号的估计值。假设有四个接收机对三个跳频网台进行接收，三个跳频信号源分别为：

$$s_1(n) = \begin{cases} \cos(2\pi \frac{f_4}{f_s} n), 1 \leq n \leq 100; \\ \cos(2\pi \frac{f_4}{f_s} n), 101 \leq n \leq 300; \\ \cos(2\pi \frac{f_3}{f_s} n), 301 \leq n \leq 390; \\ \cos(2\pi \frac{f_2}{f_s} n), 391 \leq n \leq 512; \end{cases}$$

$$s_2(n) = \begin{cases} \cos(2\pi \frac{f_4}{f_s} n + \frac{3\pi}{8}), 0 \leq n \leq 127; \\ \cos(2\pi \frac{f_2}{f_s} n + \frac{3\pi}{4}), 128 \leq n \leq 255; \\ \cos(2\pi \frac{f_3}{f_s} n), 256 \leq n \leq 383; \\ \cos(2\pi \frac{f_1}{f_s} n), 384 \leq n \leq 511; \end{cases}$$

$$s_3(n) = \begin{cases} \cos(2\pi \frac{f_3}{f_s} n), 0 \leq n \leq 127; \\ \cos(2\pi \frac{f_2}{f_s} n), 128 \leq n \leq 255; \\ \cos(2\pi \frac{f_1}{f_s} n), 256 \leq n \leq 383; \\ \cos(2\pi \frac{f_4}{f_s} n), 384 \leq n \leq 511; \end{cases}$$

其中: $f_1 = 10\text{MHz}$ 、 $f_2 = 16\text{MHz}$ 、 $f_3 = 23\text{MHz}$ 、 $f_4 = 30\text{MHz}$, 采样频率 $f_s = 140\text{MHz}$ 。

图 5.6 为源信号的时域波形和归一化时频图; 图 5.7 为混合信号的时域波和归一化时频图; 图 5.8 为分离信号的时域波和归一化时频图, 时频图的生成采用 SPWVD。

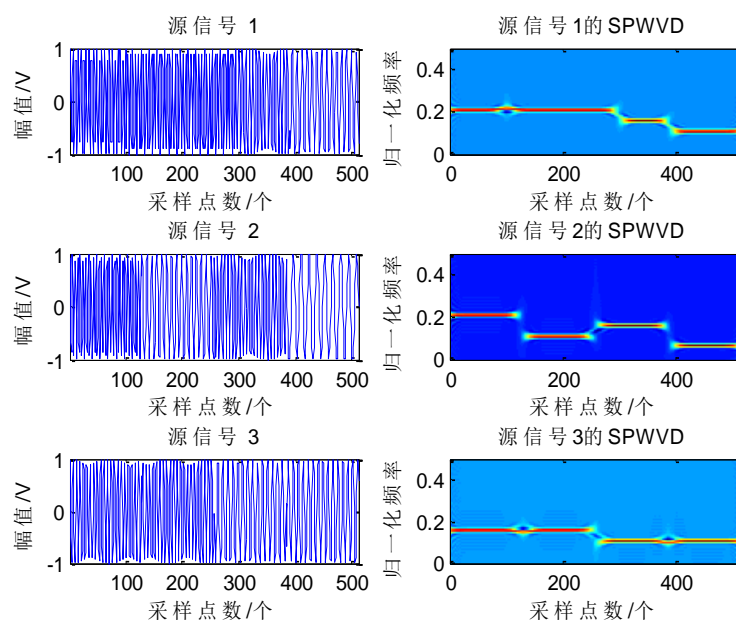


图 5.6 源信号的时域波形及其归一化时频图

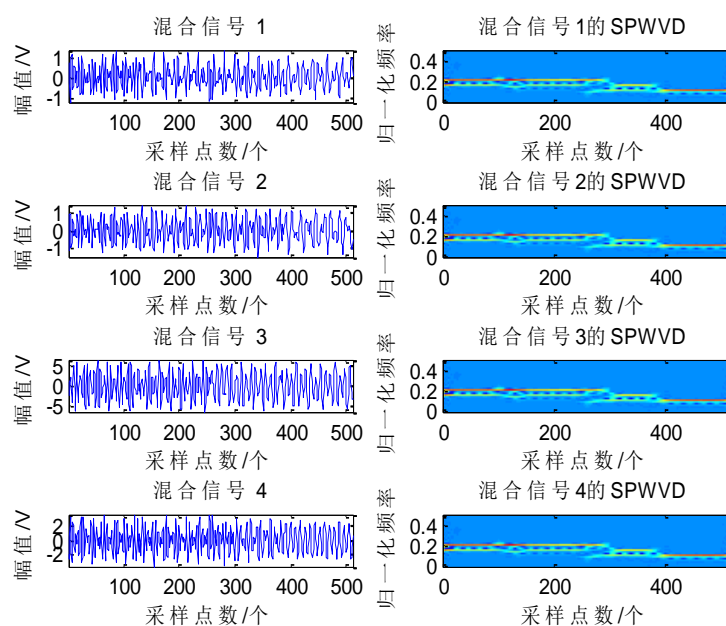


图 5.7 混合信号的时域波形及其归一化时频图

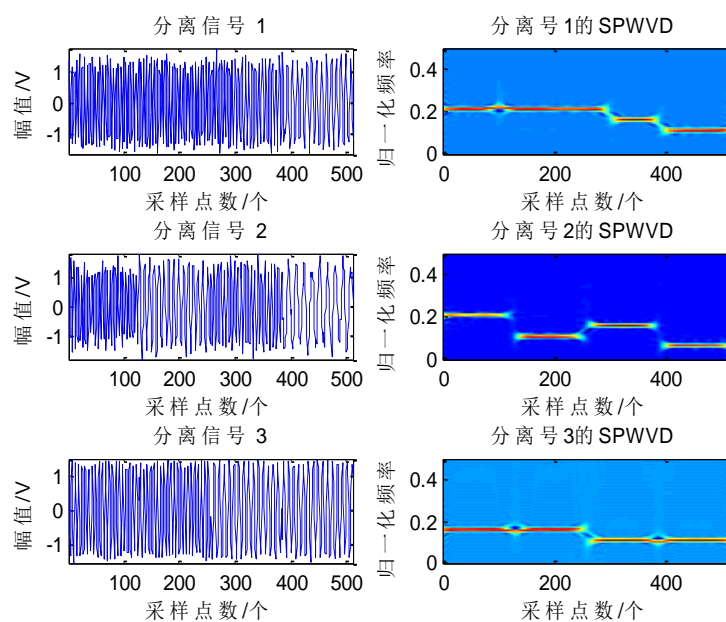


图 5.8 分离信号的时域波形及其归一化时频图

对比图 5.6 和图 5.8 可以看出，无论是在时域波形上还是在时频图上，分离信号与源信号都非常接近。为了进一步定量的评价算法的分离程度，计算性能指标 PI 来衡量全局矩阵 P 的对角化程度。如图 5.9 所示，画出了三种算法的 PI 值在不同信噪比下的取值变化情况，每次实验三种算法中使用到的混合矩阵采用同一个随机混合矩阵，每个实验结果均是 1000 次 PI 的平均值。由性能曲线可以看出，当信噪比大于 10dB 的时候，

三种算法的性能非常接近；当信噪比小于 10dB 的情况下，JDZD 算法明显优于其他两种算法。




图 5.9 PI 性能指数随信噪比变化曲线

5.6 本章小结

针对跳频信号的非平稳特性，本文提出一种基于时频矩阵的同时非正交联合对角化和非对角化盲源分离算法。这种方法在未知任何先验参数的情况下，能够根据跳频信号时频特征的差异有效分离多个跳频网台。该算法同时利用来自于自项区和交叉项区的时频分布矩阵，建立统一的代价函数，通过增加时频点来减少特征值退化的可能性，从而增强了抗噪能力。与JADE方法和TFJD方法相比，它具有更强的噪声抑制能力。在下一步的研究中，在现有时频点选择方案的基础上，进一步探寻最佳门限值的选取将是研究的重点方向。

结 论

随着通信技术的发展和电磁环境的日益复杂,通信领域中的混合信号越来越多。信号日益密集会造成同频信号混合,传统的单信号处理方法不再适用。同时,在现代军事通信中,作为非合作的通信侦察接系统,要想对敌方信号进行准确识别、解调、定位变得越来越困难。因为通信侦察系统截获的信号往往是多个信号的混合。要想对敌方信号进行盲侦察,首先必须从截获的信号中将目标信号准确分离出来。传统的时域、频域、时频域和空域信号分离方法对未知的同频信号混合均不能取得满意的分离效果,但是盲源分离技术是解决该问题的有效办法。盲源分离技术是实现盲侦察的前提。本文主要针对盲源分离技术在通信侦察系统中的应用展开研究,主要工作如下:

1. 系统介绍了通信对抗、通信侦察、盲源分离技术的概念和原理。详细介绍了通信混合信号盲分离的研究现状。

2. 对盲源分离理论进行了深入的研究。简单介绍了盲源分离的线性混合模型和分离之前的预处理,建立了盲分离的数学框架。主要介绍了几种典型的分离准则、分离算法以及信号源个数估计方法。在信号源估计方面,盖尔圆算法在低信噪比下性能优良,且在色噪声环境下仍能有效,因而应用最为广泛。在盲分离算法方面,JADE 算法性能稳定,Infomax 算法和 EASI 算法适合实时处理。最后介绍了两种评价分离效果的指标。

3. 引入时间平均峭度的概念,将其作为信号独立性的度量,从理论上证明了 ICA 可以分离确定的余弦信号,尤其是同频余弦信号。启发人们应用 ICA 分离复杂的正余弦信号(通信信号、雷达信号)。提出基于 NI PXI 的通信侦察系统的设计方案。通过试验仿真验证了 JADE 算法和 FastICA 算法对分离同频通信信号的有效性。在影响分离性能的众多因素中,主要研究了信噪比和取样时间长度对分离性能的影响。

4. 为了使 ICA 算法具有更快的和均匀一致的迭代速度,在基于负熵的 FastICA 算法基础上,提出一种改进的算法。改进算法在将最速下降法与牛顿迭代算法相结合的基础上,进一步在牛顿迭代过程中采用部分牛顿迭代。改进算法在获得均匀一致的迭代速度的前提下,进一步提高迭代速度以适应通信侦察系统对信号分离的要求。

5. 跳频通信在军事通信中越来越多的使用,给通信侦察带来了一定难度。针对跳频信号具有典型的非平稳特性,提出一种基于时频矩阵的同时非正交联合对角化和非对角化盲源分离算法。该算法同时利用来自于自项区和交叉项区的时频分布矩阵,建立统一的代价函数,通过增加时频点来减少特征值退化的可能性,从而增强了抗噪能力。与 JADE 方法和 TFJD 方法相比,它具有更强的噪声抑制能力。

本文对通信侦察信号的盲分离进行了一定的研究，虽然取得了一定成果。但是由于盲源分离理论所涉及内容的广泛性和复杂性以及作者知识结构、专业技能有限，再加之盲源分离理论还在不断发展完善中，将盲源分离技术应用到通信混合信号盲分离还有很多方面需要深入研究。为此，对今后工作的开展提出一些建议：

1. 数字调制信号如 MPSK、QAM 等大多数为复信号，他们混合而成的混合信号也为复信号，不能直接采用实数盲分离算法进行分离，否则会丢失信号的相位信息。因此对复信号的盲源分离算法研究是未来的研究方向之一。

2. 多通道盲源分离的实际应用存在一定的局限性，如部署的天线多、成本高，某些情况下地理位置的限制是的部署天线记为困难，一些场景只能采用单通道分离方法进行处理等，因此混合信号单通道盲分离方法变得日益重要。

3. 第五章中在现有时频点选择方案的基础上，有必要进一步探寻最佳门限值的选取。

4. 在无噪或噪声较小时，盲源分离算法的性能近似最优或次最优，但当噪声逐渐增大时，算法性能开始下降甚至失效。仍需进一步对高噪声条件下的盲源分离算法进行研究。

参考文献

- [1] 张贤达, 保铮. 通信信号处理[M]. 北京: 清华大学出版社, 2000.
- [2] S Haykin, Z. Chen. The cocktail problem. Neural computation[J]. 2005, 17:1875-1902.
- [3] C Jutten, J Herault. Blind separation of sources, Part I: An adaptive algorithm based on neuromimetic[J]. Signal Processing, 1991, 24(1): 1-10.
- [4] 张贤达, 保铮. 盲信号分离[J], 电子学报, 2001, 29(12A): 1766-1771.
- [5] A. J. Bell, T. J. Sejnowski. An information maximization approach to blind separation of blind deconvolution[J], Neural Computation, 1995, 7:1129-1159.
- [6] Choi S, Cichocki A, Amari S I. Flexible independent component analysis [J]. Journal of VLSI sign Processing, 2000, 26: 25-38.
- [7] 万坚, 徐世龙. 通信混合信号盲分离理论与技术[M]. 北京: 国防工业出版社, 2012: 1-3.
- [8] Winter J H. Optimum combining in digital mobile radio with cochannel interference. IEEE J. Select. Areas Commun., 1984, SAC-2: 583-593.
- [9] Yoshine H, Fukawa K, Suzuki H. Interference canceling equalizer (ICE) for mobile radio communications. Proc. IEEE Int. Conf. Commun. (ICC'94), France, 1994: 1427-1432.
- [10] Li Y, Steele R. Serial interference cancellation method for CDMA. Electronics Letters, 1994, 30(19): 1581-1583.
- [11] Divsalar D, Simon M K, Raphaeli D. Improved parallel interference cancellation for CDMA. IEEE Trans. on Commun., 1998, 46(2): 258-268.
- [12] Herault J, Jutten C. Space or time adaptive signal processing by neural network models. Neural Network for Computing, 1986, 18(4): 241-256.
- [13] Lee T W, Bell A J, Lambert R H. Blind separation of delayed and convolved sources. Advances in Neural Information Processing Systems, Cambridge, 1997: 758-764.
- [14] Cichocki A, Amari S. Adaptive blind signal and image processing: learning algorithms and applications. Chichester, U. K.: Wiley, 2002.
- [15] Hein G W, Godet J, Issler J. Status of Galileo frequency and signal design. Proc. of ION, Albuquerque, 2002.
- [16] Dankberg M D, Paired carrier multiple access (PCMA) for satellite communication. Pacific Telecommunication Conference, Honolulu, Hawaii, 1998: 787-791.

- [17] 张贤达.矩阵分析与应用[M].北京:清华大学出版社,2006.
- [18] Wu H T, Yang J F, Chen F K. Source number estimators using transformed gerschgorin radii. IEEE Trans. on Signal Proc., 1995, 43(6): 1325-1333.
- [19] Wilkinson J H. The Algebraic Eigenvalue Problem. Oxford, UK: Clarendon, 1965: 71-72.
- [20] Akaike H. A new look at the statistical model identification. IEEE Trans. Automat. Contr., 1974, AC-19: 716-723.
- [21] 杨福生,洪波.独立分量分析的原理与应用[M].北京:清华大学出版社.2006.
- [22] Hyvarinen A, et al. Independent Component Analysis. USA: John Wiley & Sons, 2001.
- [23] Bell A J, Sejnowski T J. An information-maximization approach to blind separation and blind deconvolution. Neural Computation, 1995, 7(6): 1004-1034.
- [24] 周亚乾.通信信号的盲分离技术研究[D].西安电子科技大学工程硕士学位论文,2012:13-15.
- [25] Cardoso J F, et al. Source separation using high order moments. Proc. IEEE ICASSP, 1989, 4: 2109-2112.
- [26] Cardoso J F. High order contrast for independent component analysis. Neural Computation, 1999, 11(1): 157-193.
- [27] Amari S. Natural gradient works efficiently in learning. Neural Computation, 1998, 10(2): 251-276.
- [28] Girolami M. An alternative perspective on adaptive independent component analysis algorithm. Neural Computation, 1998, 10(8): 2103-2114.
- [29] Cardoso J F, Laheld B H. Equivariant adaptive source separation. IEEE Trans. Signal Proc., 1996, 44(12): 3017-3030.
- [30] 倪晋平.水声信号盲分离算法性能评价准则[J].探测与控制学报,2002,24(2):40-44.
- [31] A.Hyvärinen, J.Karhunen, E.Oja, Independent Component Analysis. Wiley-Interscience, 2001.
- [32] T.W.Lee, Independent Component Analysis-Theory and Applications. Norwell, MA: Kluwer, 1998.
- [33] 周宗潭.董国华等.独立成分分析[M].北京:电子工业出版社,2007:123-130.
- [34] T.Ristaniemi and J.Joutsensalo, "Advanced ICA-based receivers for DS-CDMA systems," In Proc. IEEE Int. Conf. on personal, indoor, and Mobile radio

- communications (PIMRC'00), 2000.
- [35] E.Chaumette, P.Comon, D.Muller, "ICA-based technique for radiating sources estimation: application to airport surveillance" IEEE Proceedings-F, Vol.140, No.6, 1993.
- [36] PXI-5 PXI Express Hardware Specification Revision 1.0, PXI systems Alliance, August 2005.
- [37] L Gutterman, PXI Express, PXI Technology Review, Spring 2005.
<http://www.pxionline.com/columns/PXISA/>.
- [38] <http://www.ni.com/white-paper/7864/zhs/>.
- [39] 杨俊安,庄镇泉等.一种基于负熵最大化的改进的独立分量分析快速算法[J].电路与系统学报, 2002, 7(4): 37-40.
- [40] Hyvainen A. Fast and robust fixed-point algorithms for independent component analysis. IEEE Trans. on Neural Networks, 1999, 10(3): 626-634.
- [41] P.Tiehavsky, Z.Koldovs and E.Oja. Performance analysis of the FastICA algorithm and Cramer-Rao bounds for linear independent component analysis[J]. IEEE Transactions on Signal Processing, 2006, 54(4): 1189- 1203.
- [42] V.Zarzoso, P.Comon. ComParative speed analysis of FastICA[J]. Lecture Notes in Computer Science, 2007, 4666(53): 293-300.
- [43] 蒋长锦.科学计算和 C 程序设计[M],第一版.安徽:中国科学技术大学出版社,1998.
- [44] 曾兴雯,刘乃安,孙献璞.扩展频谱通信及其多址技术[M].西安: 西安电子科技大学出版社,2004.
- [45] 陈新宁. 跳频通信侦查技术研究[D]. 国防科学技术大学硕士学位论文: 2006.
- [46] 翟海莹,杨小牛,王文勇.基于盲源分离的跳频网台分选[J].中国电子科学研究院学报,2008, 3 (4) : 398-402.
- [47] 张朝阳,曹千芊,陈文正.多跳频信号的盲分离与参数盲估计[J].浙江大学学报, 2005,39(4):465-470.
- [48] Belouchrani A , Amin M G. Blind source separation based on time-f requency signal representations[J]. IEEE Trans. on Signal Processing, 1998 ,46 (11): 2888-2897.
- [49] 杨利虎,张尔杨.基于数字信道化和空时频分析的多网台跳频信号 DOA 估计[J].通信学报,2012,30(10):68-74.
- [50] 杨小牛.软件无线电技术与应用[M].北京:北京理工大学出版社,2010.115-123.

- [51] 杨利虎.跳频信号的侦察技术研究[D].国防科学技术大学博士学位论文:2009.
- [52] P Flandrin, Time-Frequency/Time-Scale Analysis[M]. New York: Academic Press, 1999.
- [53] Yimin Zhang, Weifeng Mu, and Moeness G Amin. Subspace analysis of spatial time frequency distribution matrices[J]. IEEE Transactions on Signal Process, 2001, 49(4): 747-759.
- [54] 郭靖.盲源分离的时频域算法研究[D].重庆大学.2012.
- [55] A Belouchrani, K Abed-Meraim, M G Amin, and A M Zoubir, Joint anti-diagonalisation for blind source separation[C], in Proc. Int. Conf. Acoustic Speech, Signal Processing, (ICASSP 2001), Salt Lake City, UT, May 2001, pp. 2789–2792.
- [56] El Mostafa Fadaili, Nadège Thirion Moreau, and Eric Moreau. Nonorthogonal Joint Diagonalization/Zero Diagonalization for Source Separation Based on Time-Frequency Distributions[J]. IEEE Transactions on Signal Process, 2007, 55(5) : 1673–1687.
- [57] L Cirillo, A Zoubir, N Ma, and M G Amin, Automatic classification of auto- and cross-terms of time-frequency distributions in antenna arrays[C].in Proc Int Conf Acoustic, Speech, Signal Processing (ICASSP), Orlando, FL, May 2002, II:1445–1448.
- [58] L Cirillo and M G Amin, Auto-term detection using time-frequency array processing[C]. in Int Conf Acoustic, Speech, Signal Processing(ICASSP), Honk-Kong, Apr 2003,VI: 465–468.
- [59] A Belouchrani, K Abed-Meraim, M G Amin, A M Zoubir. Blind Separation of Nonstationary Sources[J]. IEEE Signal Processing Lett, 2004, 11(7) :605–608.
- [60] L Giulieri, N Thirion-Moreau, and P-Y Arquès, Blind sources separation based on bilinear time-frequency representations: A performance analysis[C]. in Proc Int Conf Acoustic, Speech, Signal Processing (ICASSP), Orlando, FL,2002:1649–1652.

攻读硕士学位期间发表的论文和取得的科研成果

- [1] Zhang Xiaolin, Xu Hongrui. The Blind of Co-Frequency Communications Recon Signals. IMCC. September 23, 2013, Papers: 1394-1398(EI 源)

致 谢

光阴荏苒，岁月如梭。一转眼我已在哈尔滨工程大学度过了一千多个日日夜夜。我将完成我研究生阶段的学习与生活，即将再一次踏出校门。回望过往，得到了老师、家人和同学的许多关心和帮助。请允许我在这里表达我最诚挚的谢意。

首先，衷心感谢我的研究生导师张晓林副教授。张老师给我的学术研究指明了方向，对我在学术中所遇到的各种疑难问题给予了悉心的指导。张老师不仅学识渊博，而且科研经验十分丰富，和张老师的每次学术交流都让我受益匪浅。他严谨的治学之风和对事业的孜孜追求将影响和鼓励我的一生。

其次，感谢我的父母。是他们一直在精神上和物质上对默默地支持着我，使得我在工作之后又重新选择读研。有了他们的陪伴，让我感觉鼓励如影随形，幸福无处不在。

同时，还要感谢哈尔滨工程大学信息与通信工程学院的全体老师，尤其是姜涛老师、张薇老师、孙志国老师、安澄全老师，在他们无私、高质量的传授中，我在学习中更多的汲取了专业知识并提升了能力。还要感谢何林飞师弟以及 402 实验室的全体同学，感谢他们给予我的支持和帮助。

最后，对评阅本论文的各位专家致以衷心的感谢。